

# TACT: 面向大型語言模型自我一致性投票的信任錨定信心調節

柯瑋宸 (Wei-Chen Ko, vito1317) — 獨立研究者

## 摘要

當凍結模型自我回報的信心在方向上校準正確時，信心加權自我一致性能勝過多數決。然而現有的加權方案一律是信心的單調遞增函數，因此反相關的通道會毒化投票；而二元校準閘門雖能在反轉下存活，代價是連帶捨棄仍具辨別力的訊號。TACT (Trust-Anchored Confidence Tempering, 信任錨定信心調節) 改由通道實測的帶符號題內辨別度推導投票指數：以帶題目叢集標準誤的混合 van Elteren Somers'  $D$  為基礎，經正部 James–Stein 收縮，再經 Bayes 判別連結；在預設基礎率  $\bar{p} = \frac{1}{2}$  下，整式化簡為  $\gamma = z\sqrt{2 + z^2}$ ，其中  $z$  為收縮後合併 AUC 的 probit。收縮死區之內，投票與純自我一致性位元層級相同。本文另提出無標籤變體，自一致性偽標籤估計符號，並在衰減恆等式下保證：只要多數決錯誤率低於二分之一，符號估計必為一致；越過該邊界後它會判錯符號，本文對此如實量測並報告。在合成 oracle 實驗中，此變體恢復了使所有已發表協定停留在多數決基準線的反相關通道 (1.000 對 0.762)，並在對自我一致性零配對損失的前提下突破異質性基準線 (0.923 對 0.785)。但相對於 dev 上選取的帶符號網格——掃描顯示它是遠比已發表協定更強的基線——優勢收窄到失真、回音與無標籤運作三處。兩次真實軌跡實驗界定了設定的邊界：通道在飽和基準上為零 ( $z = -1.24$ )，在競賽數學上為正 ( $\bar{D} = +0.250$ ,  $z = +2.54$ )；然而任何這類方法能作用的分層，在兩個領域五個基質上只佔題目的 2.5–7.5%。因此棄權是正確的預設，而死區恰好實現了它。

關鍵詞：大型語言模型、自我一致性、信心校準、無標籤估計、排名統計量

## 一、引言

自我一致性 (Self-Consistency, SC) [1] 透過取樣  $K$  條思維鏈並回傳多數答案，提升凍結大型語言模型的推理準確率。由於每條推理軌跡亦可附帶信心分數 (口頭表述 [2][3]、由 token 對數機率導出、或以  $P(\text{True})$  形式引出 [4])，以信心加權投票是自然的改良方向。CISC (Confidence-Informed Self-Consistency) [5] 證明此作法能以較低的取樣預算達到純 SC 的準確率，並提出題內辨別度 (Within-Question Discrimination, WQD) 指標，指出對投票真正有用的性質是辨別力，而非校準度。

然而這類改良存在一項結構性弱點，就我所知尚無已發表方法處理。現有加權方案，包括 CISC 的 softmax 權重、可靠度感知偽計數 [6] 與暖啟動門檻過濾 [7]，皆為信心的單調遞增函數；換言之，方法只能決定「上調權重的幅度」，卻無法表達「信心可能與正確性反相關」。方向性失準並非罕見情形：強化微調已知會扭曲口頭信心，分布位移也可能使原本有效的訊號反轉。本文實驗顯示，一條簡單的負相關通道 ( $\kappa = -0.6$ ，見第三節) 足以將信心加權基線從近乎完美壓到遠低於多數決基準線；但同一份證據若以正確的符號解讀，其實是完美訊號。另一種防禦性作法是在校準誤差過高時以二元閘門關閉信心通道，此法雖可在符號反轉下存活，卻會把仍具辨別力的訊號一併丟棄：一條系統性偏低但排序完全正確的信心通道，會因與投票效用無關的理由而未能通過 ECE 閘門 [5][8]。

本文將問題歸結為估計單一純量，即信心通道的帶符號題內辨別度，再連同其不確定性映射為投票指數。主要貢獻如下。

**C1: 帶符號且解析推導的信心加權。** TACT 以權重  $w_i = \exp(\gamma \varphi_i)$  投票，其中  $\varphi_i$  為軌跡  $i$  題內信心中位秩的標準化 van der Waerden 分數；指數  $\gamma$  並非網格搜尋所得，而是由統計量推導：先計算混合 van Elteren Somers'  $D$  (等於  $2 \cdot \text{WQD} - 1$ )，配上精確的 tie 校正零假設變異數與題目叢集 jackknife 標準誤，經帶顯著性下限的正部 James–Stein 收縮，最後經 Bayes 判別連結。有兩處端點是精確的：收縮死區內的投票與純 SC 位元層級相同 (兩者共用同一段程式碼)，採用對數值特徵映射時則精確重現 CISC-power (第四節)。由於  $\varphi$  僅透過題內排名依賴信心，任何嚴格單調的信心尺度失真都不影響投票；在單調壓縮情形下，本方法勝過測試網格  $\{0.25, 0.5, 1, 2, 4\}$  中最好的指數 (1.000 對 0.963)。該格的最佳點位於網格所試的最大指數，因此這項比較界定的是此網格，而不是整個原始值權重家族。

**C2: 帶符號通道可靠度的無標籤估計。**群眾外包文獻由多位標註者之間的共變異估計可靠度 [9][10]; 單一模型的單一信心通道並無此結構可用。本文改從一致性偽標籤 (每題的去重加權多數決) 估計帶符號辨別度, 並證明類別條件雜訊下的衰減恆等式  $\mathbb{E}[\widehat{D}_g] = (1 - 2\bar{\rho}) D$ : 只要成對加權的多數決錯誤率  $\bar{\rho}$  低於  $1/2$ , 無標籤估計至多低估信任強度, 不會判錯符號。方法另以 split-half 一致性反演保守地去衰減, 並在識別性受威脅時由符號感知警報退回純 SC。實驗中, 無標籤變體與使用 200 筆標籤的變體在整條耦合掃描上幾乎逐點相同, 包括負通道的完整恢復 (第八節)。越過  $\bar{\rho} < 1/2$  之後會發生什麼, 第九節有實測, 答案不好看。

**C3: 不可能性結果與其結構化出路。**當逐題耦合為 i.i.d. 且無可觀測共變量時, 本文證明逐題無標籤自適應不可行: 對題目自身一致性統計量的任何單調使用, 都會塌縮為對多數決的增強; 在多數決錯誤且  $|D_g| > 0.3$  (亦即翻轉才可能獲勝) 的題目上, 可觀測符號有 96% 的比例與真實符號相反; 且在池實質為二元時,  $\{\kappa > 0, \text{少數方正確}\}$  與  $\{\kappa < 0, \text{多數方正確}\}$  兩種情形產生完全相同的可觀測分布。反之, 若異質性由可觀測共變量索引 (例如不同領域各有其校準特性), 同一估計器按群組執行即可恢復各群組的帶符號耦合, 並在對 SC 零配對損失的前提下逼近逐題最佳結果 (第六節)。

**C4: 預先登記的證偽協定。**四項證偽準則於實作前即已固定, 其中兩項的設計目的就是推翻本方法: 已發表的 dev 校準 CISC 協定 (其調參溫度本身即為 SC 與 CISC 之間的內插), 以及在 dev 上選取帶符號指數的網格基線——掃描顯示後者遠比前者更強。四項準則全數通過, 且各項邊際如實報告: 相對帶符號網格的淨優勢僅集中於三種情形, 即單調失真、自信回音, 以及網格基線無法執行的無標籤運作; 在同質掃描的中段, 本方法其實是落後的, 這一點由十 seed 的自助法區間確立為系統性而非雜訊。

**C5: 量測可作用的分層。**兩次真實軌跡實驗與五個基質的窗口量測, 界定了任何無標籤聚合方法實際能處理的範圍。通道在飽和基準上為零 ( $\widehat{D} = -0.219, z = -1.24$ ), 在競賽數學上為正 ( $\widehat{D} = +0.250, z = +2.54$ ), 顯示模型不確定時, 方法所需的前提確實可能成立; 但跨兩個領域五個基質, 可作用的分層仍只佔題目的 2.5–7.5%, 而且題目變難時沒有變寬。兩個真實基質上的池內 oracle 都無法通過預先登記的終點, 因此棄權是正確的預設。

## 二、相關工作

**信心加權自我一致性。**SC [1] 將取樣軌跡視為獨立同分布的票。CISC [5] 以在標籤分割上調參的溫度執行 softmax 信心加權, 其 WQD 指標提出的「辨別力重於校準度」論點與本文動機相同; 排名校準文獻 [8] 亦獨立得到相同結論。加權變體 [11] 與提早停止方法 [12][13] 著眼於預算效率。Self-Certainty [14] 在概念上最接近本文, 因為它是已發表候選選擇器中唯一採用近似排名分數的方法; 但它跨候選項目排名、方向固定為正, 本文也沒有把它列入評測。可靠度感知偽計數 [6] 與暖啟動門檻過濾 [7] 可線上調整, 但僅能重新縮放正向信任。上述方法都不搜尋負指數; 障礙在超參數網格少了一個符號位元, 不在權重家族本身。本文自己的 SignGrid-dev 基線把同一個  $c^\gamma$  家族開放至負  $\gamma$  後, 即可在整條負半軸達到帶符號 oracle。現有協定沒有任何一個會估計這個符號, 不論有沒有標籤。基於此, 本文的 dev 校準變體須誠實定位: CISC 的調參溫度已構成 dev 校準的 SC 與 CISC 內插, 故 TACT-dev 的新意在於符號處理、排名不變性與免網格的解析映射, 而非 dev 校準本身。

**無標籤可靠度估計。**由一致性推估工作者可靠度是統計學的經典問題 [9][15][16]; 頻譜元學習 [10] 與近期結合多個 LLM 的研究 [17][18] 均仰賴多個預測器之間的共變異。本文的設定不同: 僅有單一模型的單一通道、逐題投票結構, 且一致性代理在相關錯誤下的失效是已知現象。本文的因應方式是給出量化的衰減恆等式、保守的去衰減與警報機制, 而非宣稱無條件保證。

**收縮與排名統計量。**估計器由經典工具組成: 分層排名統計量 [19]、James-Stein 正部估計器 [20]、有效樣本數修正 [21][22], 以及 normal-scores 判別分析。本文的貢獻在於組裝方式與其端點性質, 而非個別工具。

**先前的負面結果。**我先前提出的系統 RLEV-VoI (冗餘折扣投票搭配資訊價值停止準則) 曾以相同的證偽紀律評估, 結果未能通過: 一個簡單的去重基線在所有情境全面勝出, 因此我將該系統以負面結果發表。正是在分析那次失敗的過程中, 我注意到了本文所研究的信心兩難。

### 三、問題設定

#### 3.1 記號

本文使用的全部符號依首次出現順序整理於附錄的表 7，並依首次引入符號的章節分組。設題目  $q = 1, \dots, Q$ ，題  $q$  有  $m_q$  條取樣軌跡。軌跡  $(q, i)$  產生離散答案  $a_{q,i}$  與信心  $c_{q,i} \in (0, 1)$ ；正確性  $y_{q,i} = \mathbf{1}[a_{q,i} = a_q^*]$  於測試時不可觀測。純 SC 回傳  $\arg \max_A n_q(A)$ ，其中  $n_q(A)$  為答案  $A$  的得票數。CISC-power 以固定  $\gamma > 0$  依  $c_{q,i}^\gamma$  加權。

#### 3.2 信心兩難

實驗採用的合成 oracle 逐題自含潛在正確答案的叢集混合分布取樣軌跡，信心依下式生成：

$$c_{q,i} = \text{clip}\left(\frac{1}{2} + \kappa(y_{q,i} - \frac{1}{2}) + \varepsilon_{q,i}, 0.01, 0.99\right)$$

其中  $\varepsilon \sim \mathcal{N}(0, 0.1^2)$  為雜訊， $\kappa \in [-0.6, 0.6]$  為耦合強度。圖 1 為本方法設計之前先行量測的基線結果：無條件加權（CISC， $\gamma = 1$ ）在  $\kappa < 0$  時崩潰；ECE 閘門僅在校準良好時開啟；以 dev 標籤執行符號校正的 AUC 閘門則幾乎吃滿整條同質掃描。這項預先量測界定了新方法能夠正當宣稱優勢的範圍，即信心尺度的單調失真、共變量異質性、小型 dev 集與無標籤運作四種情形；後續評測亦以此為準。




Figure 1: 圖 1：預先量測的問題陳述。固定  $K = 15$  下，各基線信心策略的準確率隨真實耦合  $\kappa$  的變化。符號校正 AUC 閘門（綠線）幾乎吃滿同質掃描；新方法的剩餘空間（陰影）集中於中段，以及本圖之外的失真、異質性與無標籤情形。

### 四、TACT

#### 4.1 投票家族

在題  $q$  內，令  $R_{q,i}$  為  $c_{q,i}$  的中位秩（同分取平均），並定義

$$\varphi_{q,i} = \frac{v_{q,i} - \bar{v}_q}{\sigma_q}, \quad v_{q,i} = \Phi^{-1}\left(\frac{R_{q,i}}{m_q + 1}\right)$$

其中  $\sigma_q$  為  $v$  在題內的實測標準差。此處不可改用閉式常數：無同分時  $m = 4$  的值約 0.62， $m = 40$  時約

0.95，閉式常數會使  $\gamma$  在不同預算下被悄悄重新縮放。若  $\sigma_q \leq 10^{-8}$ （信心全數同分），則令  $\varphi \equiv 0$ ，該題退回純 SC 投票。投票規則為

$$\hat{a}_q = \arg \max_A \sum_{i: a_{q,i}=A} \exp(\gamma \varphi_{q,i})$$

當  $\gamma = 0$  時，實作直接呼叫 SC 常式本身，因此零信任端點為位元層級精確，而非僅在分布意義上相等。又因  $\varphi$  僅透過題內排名依賴  $c$ ，信心尺度的任何嚴格單調失真皆不改變投票結果。

## 4.2 可靠度統計量

對正標籤數  $n_q^1$ 、負標籤數  $n_q^0$  的題  $q$ （dev 情形以  $y$  為標籤，無標籤情形以第五節的偽標籤代替），由中位秩上的 Mann–Whitney 統計量可得

$$D_q = 2 \text{AUC}_q - 1, \quad \text{AUC}_q = \frac{U_q}{n_q^1 n_q^0}$$

此即 CISC 記號中的  $2 \cdot \text{WQD}_q - 1$ 。跨題混合採 van Elteren 成對計數權重  $N_q = n_q^1 n_q^0$  [19]：

$$\widehat{D} = \frac{\sum_q N_q D_q}{\sum_q N_q}$$

在題內可交換性的零假設下， $U_q$  的精確 tie 校正變異數為  $n_q^1 n_q^0 (m_q + 1) / 12 \cdot [1 - \sum_t (t^3 - t) / (m_q^3 - m_q)]$ ，由此得零假設標準誤  $\text{SE}_0$ ；題間異質性另以閉式的刪一題 jackknife 標準誤  $\text{SE}_J$  捕捉。實際使用的標準誤取保守值：

$$\text{SE} = \max(\text{SE}_0, \text{SE}_J, \frac{1}{2\sqrt{N}}), \quad r = \widehat{D} / \text{SE}$$

由於  $D$  為成對泛函， $\mathbb{E}[\widehat{D}]$  與  $m_q$  無關；在  $m = 40$  下估得的指數可直接用於  $m = 8$  的部署情境。

## 4.3 調節映射

收縮。採帶顯著性下限  $\nu$  的正部 James–Stein：

$$\tilde{D} = \text{sign}(\widehat{D}) \max(0, |\widehat{D}| - \nu^2 \text{SE}^2 / |\widehat{D}|)$$

死區為  $\{|r| \leq \nu\}$ ，取  $\nu_{\text{dev}} = 1.28$ 、 $\nu_{\text{LF}} = 2.33$ 。當  $\nu = 1$  時，上式恰為  $\mathcal{N}(0, \tau^2)$  先驗搭配插入式估計  $\hat{\tau}^2 = \max(0, \widehat{D}^2 - \text{SE}^2)$  所得的經驗 Bayes 後驗平均值 [20]。此映射為奇函數且連續，幅度不超過  $|\widehat{D}|$ ，對  $\widehat{D}$  單調、對 SE 反單調。

連結。設題內  $\varphi | y \sim \mathcal{N}(\mu_y, s^2)$ ，且混合分布已標準化為單位變異數（此即 4.1 節標準化的效果），故  $s^2 = 1 / (1 + \bar{p}(1 - \bar{p})u^2)$ ，其中  $u = \sqrt{2} \Phi^{-1}(\frac{1+\tilde{D}}{2})$ ， $\bar{p}$  為正確軌跡的基礎率。在此模型下，Bayes 最適的逐軌跡對數權重係數為

$$\gamma^* = \frac{u}{s} = u \sqrt{1 + \bar{p}(1 - \bar{p})u^2}$$

並以  $\gamma_{\max}$  為上限 (dev 取 4, 無標籤取 2)。若省略混合變異數校正而直接取  $\gamma = u$ , 在  $D = 0.9$  時會低估強通道的權重約五成。連結假設題內  $\varphi$  服從常態分布, 但式 (4.1) 的 normal score 只有在漸近下才提供這項近似;  $m_q = 4$  時, 標準化前的分數只有四個可能值。採用實測  $\sigma_q$  能修正尺度影響, 卻沒有解決分布形狀的誤差。這個問題在本文主張的小預算設定中最尖銳: 估計可在  $m = 40$  完成, 部署卻可能只有  $m = 8$ 。當  $\widehat{D}$  飽和、指數碰到上限時, 連結形狀不再重要; 小  $m$  才是它必須有效、同時理據最弱的地方。

#### 4.4 TACT 的單一公式

兩處代數化簡讓整條 pipeline 收成一個式子。把  $\widehat{D}$  從收縮式中提出來, James-Stein 就變成合併  $z$  統計量  $\zeta = \widehat{D}/\text{SE}$  的純乘法增益; 把  $u = \sqrt{2}z$  代進連結函數, 巢狀根號消失。TACT 即:

$$\hat{a}_q = \arg \max_A \sum_{i: a_{q,i}=A} \exp(\gamma \varphi_{q,i}), \quad \gamma = \left[ z \sqrt{2 + 4\bar{p}(1-\bar{p})z^2} \right]_{-\gamma_{\max}}^{\gamma_{\max}}$$

$$z = \Phi^{-1}\left(\frac{1}{2}[1 + \widehat{D}(1 - \nu^2/\zeta^2)_+]\right), \quad \zeta = \widehat{D}/\text{SE}$$

在預設  $\bar{p} = 1/2$  下, 指數恰為

$$\gamma = z\sqrt{2 + z^2}, \quad z = \Phi^{-1}\left(\frac{1+\widehat{D}}{2}\right)$$

——一個 probit、一個平方根, 全式沒有任何調校常數 ( $\nu$  是顯著水準、 $\gamma_{\max}$  是截斷, 兩者都在看資料前就固定)。死區現在是單一條件  $|\zeta| \leq \nu$ , 在其上  $\gamma$  恆為 0, 投票位元等同 SC。此式已對現行實作在含所有邊界的隨機輸入上驗證等價 (tests/test\_formula.py)。

這裡的  $\widehat{D}$  是式 (4.2) 跨題合併後再收縮的統計量, 不能換成單題的  $\text{AUC}_q$ 。  $\gamma_{\max}$  也不是裝飾性的記號: 當  $\widehat{D}$  接近飽和時, 真正進入投票的是截斷後的  $\gamma_{\max}$ , 不是連結函數算出的原始幅度。因此飽和格主要驗證符號是否正確; 連結函數的形狀真正承重之處, 是尚未碰到截斷的中等耦合區。

#### 演算法 1: TACT (有標籤 dev 路徑)

輸入 (Require): 帶真值的 dev 軌跡池  $\mathcal{D}$ 、測試軌跡池  $\mathcal{T}$ 、每題預算  $K$ 、顯著性下限  $\nu$ 、截斷  $\gamma_{\max}$ 。

輸出 (Ensure): 一個全域純量  $\gamma$ ; 每個  $q \in \mathcal{T}$  的答案  $\hat{a}_q$ 。

| 行  | 完整偽程式碼                                                                                        | 說明                     |
|----|-----------------------------------------------------------------------------------------------|------------------------|
| 1  | $\mathcal{S} \leftarrow \emptyset, \quad H \leftarrow \emptyset$                              | 初始化統計集合與標籤集合           |
| 2  | 對每個 $q \in \mathcal{D}$ 執行                                                                    | dev 題目迴圈               |
| 3  | $y_i \leftarrow \mathbf{1}[a_{q,i} = a_q^*], \quad i \leq K; \quad H \leftarrow H \cup \{y\}$ | 建立正確性標籤並保存所有標籤         |
| 4  | 若 $0 < \sum_i y_i < K$ 則                                                                      | 只讓同時含正確與錯誤軌跡的題目進入辨別度估計 |
| 5  | $R \leftarrow c_{q,1:K}$ 的題內中位秩                                                               | 同分取平均秩                 |
| 6  | $D_q \leftarrow 2U_q/(n_q^1 n_q^0) - 1$ , 其中 $U_q$ 由 $R$ 計算                                   | 題內 Somers' $D$         |
| 7  | $\mathcal{S} \leftarrow \mathcal{S} \cup \{(D_q, N_q, \text{Var}_0(D_q))\}$                   | 保存效果量、成對權重與零假設變異數      |
| 8  | $\widehat{D} \leftarrow \sum_q N_q D_q / \sum_q N_q$                                          | van Elteren 合併         |
| 9  | $\text{SE} \leftarrow \max\{\text{SE}_0, \text{SE}_J, 1/(2\sqrt{N})\}$                        | 採用保守標準誤                |
| 10 | $\bar{p} \leftarrow \text{clip}(\text{mean}(H), 0.05, 0.95)$                                  | 估計正確軌跡基礎率              |
| 11 | $\zeta \leftarrow \widehat{D}/\text{SE}$                                                      | 合併的 $z$ 統計量            |

| 行  | 完整偽程式碼                                                                                  | 說明                   |
|----|-----------------------------------------------------------------------------------------|----------------------|
| 12 | 若 $ \zeta  \leq \nu$ 則                                                                  | 死區                   |
| 13 | $\gamma \leftarrow 0$                                                                   | 完全退回 SC              |
| 14 | 否則                                                                                      | 證據超過顯著性下限            |
| 15 | $\widetilde{D} \leftarrow \widehat{D}(1 - \nu^2/\zeta^2)$                               | 正部 James–Stein 收縮    |
| 16 | $z \leftarrow \Phi^{-1}((1 + \widetilde{D})/2)$                                         | probit 映射            |
| 17 | $\gamma \leftarrow \text{clip}(z\sqrt{2 + 4\bar{p}(1 - \bar{p})}z^2, \pm\gamma_{\max})$ | Bayes 判別連結與截斷        |
| 18 | 對每個 $q \in \mathcal{T}$ 執行                                                              | 測試題目迴圈               |
| 19 | 若 $\gamma = 0$ 則                                                                        | 零信任分支                |
| 20 | $\hat{a}_q \leftarrow \text{SC}(a_{q,1:K})$                                             | 呼叫同一個 SC 常式，確保位元完全相同 |
| 21 | 否則                                                                                      | 信心加權分支               |
| 22 | $\varphi \leftarrow c_{q,1:K}$ 的標準化 van der Waerden 分數                                  | 僅使用題內排名              |
| 23 | $\hat{a}_q \leftarrow \arg \max_A \sum_{i:a_{q,i}=A} e^{\gamma\varphi_i}$               | 合併加權票數               |
| 24 | 回傳 $\gamma, \{\hat{a}_q\}$                                                              | 輸出全域指數與各題答案          |

dev 與測試兩個迴圈的成本皆為每題  $O(K \log K)$ ，主要來自題內排序。從 dev 傳到測試的只有一個純量  $\gamma$ ，沒有逐題參數；死區因此代表全域棄權，不是事後挑掉不利題目。

#### 4.5 端點性質

**命題 1 (SC 精確歸約)。**  $\gamma = 0$  時，投票在任何軌跡池上與純 SC 為同一函數，平手處理亦相同。在  $D = 0$  下， $P(\gamma = 0) \rightarrow 2\Phi(\nu) - 1$  (dev 約 80%，無標籤約 98%)，且  $\gamma$  在死區邊界連續，因此偽陽性僅施加一個任意小的指數。

**命題 2 (CISC 精確歸約)。** 取特徵映射  $\varphi_{q,i}^{\log} = \log c_{q,i} - \overline{\log c_q}$  時，權重等於  $\lambda_q c_{q,i}^\gamma$ ，其中  $\lambda_q > 0$  為逐題常數，與信心模型中的耦合  $\kappa$  不同；故  $\arg \max$ 、平手情形與正規化得票份額均與 CISC-power( $\gamma$ ) 一致。

**命題 3 (正則性)。** 複合映射  $g(\widehat{D}, \text{SE})$  連續、為奇函數、對  $\widehat{D}$  非遞減、幅度對 SE 非遞增，且  $g(D, 0^+) = \gamma^*(D)$ 。

以上命題的證明均為初等推導，並由公開程式碼中的單元測試驗證（共 102 項，其中零假設變異數以置換檢定驗證，收縮式的經驗 Bayes 恆等式與連結推導亦各有數值測試）。

## 五、無標籤估計

### 5.1 管線

估計流程分四步。第一步去重：在字面相似度通道上以門檻 0.95 做單鏈結分群，每條軌跡於多數決判定與成對加權中的權重為其所屬群大小的倒數。第二步偽標籤： $g_{q,i} = \mathbf{1}[a_{q,i} = M_q]$ ，其中  $M_q$  為去重加權多數。第三步 margin 閘門：僅保留去重加權 margin 位居前六成的題目。第四步以  $\text{lab} = g$  計算 4.2 節的統計量，得  $(\widehat{D}_g, \text{SE}_g, r_g)$ 。

#### 演算法 2: TACT-LF（完全無標籤路徑）

**輸入 (Require):** 軌跡池  $\mathcal{P}$ 、預算  $K$ 、去重門檻  $\theta = 0.95$ 、margin 分位數  $\beta = 0.40$ 、顯著性下限  $\nu_{\text{LF}}$ 、截斷  $\gamma_{\max}$ 、隨機分割次數  $J = 20$ 、衰減量下限 0.20、minGated。下列  $\hat{\eta}$  代表估計的衰減量  $1 - 2\bar{\rho}$ ，不是  $\bar{\rho}$ 。

**輸出 (Ensure):** 指數  $\gamma$ ；任一警報觸發時， $\gamma$  必為 0。

| 行  | 完整偽程式碼                                                                                | 說明                |
|----|---------------------------------------------------------------------------------------|-------------------|
| 1  | 對每個 $q \in \mathcal{P}$ 執行                                                            | 題目迴圈              |
| 2  | $w_i \leftarrow 1/ \text{group}(i) $ , 群組由 $\text{dup} \geq \theta$ 的單鏈結分群取得          | 去重權重              |
| 3  | $M_q \leftarrow \arg \max_A \sum_{i:a_{q,i}=A} w_i$                                   | 去重加權多數答案          |
| 4  | $\text{mgn}_q \leftarrow$ 前兩名去重加權得票份額之差                                               | 多數決 margin        |
| 5  | $G \leftarrow \{q : \text{mgn}_q \geq Q_\beta(\text{mgn}), \text{至少有兩個相異答案}\}$        | margin 閘後集合       |
| 6  | $E_1 \leftarrow [\text{median}_q(\text{Kish 比}) < 0.5]$                               | 重複塌縮警報            |
| 7  | $E_4 \leftarrow [ G  < \text{minGated}]$                                              | 有效題數不足警報          |
| 8  | 對 $q \in G$ , 令 $g_{q,i} \leftarrow \mathbf{1}[a_{q,i} = M_q]$                        | 建立一致性偽標籤          |
| 9  | $(\widehat{D}_g, \text{SE}_g, z_g) \leftarrow$ 以 $g$ 在 $G$ 上計算的合併統計量                  | 原始帶符號辨別度          |
| 10 | $s \leftarrow \text{sign}(\widehat{D}_g)$                                             | 估計信任方向            |
| 11 | $E_2 \leftarrow [\psi(s) > 0.05]$                                                     | 符號感知的 margin 去耦警報 |
| 12 | $\alpha \leftarrow J$ 次分割所得的兩半多數決平均一致率                                                | split-half 一致性    |
| 13 | $k \leftarrow$ 非多數答案質量的逆 Simpson 有效數                                                  | 有效錯誤選項數           |
| 14 | $p \leftarrow [1 + \sqrt{1 - (k+1)(1 - k\alpha)}]/(k+1)$                              | 反解單硬幣模型           |
| 15 | $E_3 \leftarrow [\text{判別式} < 0.02]$                                                  | 根歧義警報             |
| 16 | $\hat{\eta} \leftarrow \text{clip}(\text{UCB}_{95}(2p-1), 0.20, 1)$                   | 保守估計衰減量           |
| 17 | 若 $E_1 \vee E_2 \vee E_3 \vee E_4$ , 或 $ z_g  \leq \nu_{\text{LF}}$ 則                 | 警報或原始顯著性不足        |
| 18 | 回傳 0                                                                                  | 拒絕加權, 投票維持 SC     |
| 19 | 回傳 $\text{Temper}(\widehat{D}_g/\hat{\eta}, \text{SE}_g/\hat{\eta})$ , 且不設定 $\bar{p}$ | 只在通過檢查後去衰減並調節     |

演算法 2 裡有兩處次序在承重。第 17 行的顯著性閘門檢驗的是原始的  $z_g$ , 因為命題 4 只在其條件成立時保證它的符號不偏; 第 19 行的調節才用去衰減後的那一對數值  $(\widehat{D}_g/\hat{\eta}, \text{SE}_g/\hat{\eta})$ 。若改以放大後的統計量做檢驗, 去衰減本身就會製造出顯著性。完全無標籤路徑也不套用式 (4.3) 的混合基礎率校正, 因為  $\bar{p}$  正是無標籤設定不知道的量; 實作將它保持為未設定, 而不是以多數比例冒充正確率。

## 5.2 符號一致性及其邊界

**命題 4 (衰減恆等式)。**令  $\bar{\rho}$  為題目多數決錯誤的成對加權機率。若多數決錯誤事件在給定  $y$  下與  $\varphi$  獨立 (類別條件雜訊假設), 則  $\mathbb{E}[\widehat{D}_g] = (1 - 2\bar{\rho}) D$ 。因此只要  $\bar{\rho} < 1/2$ , 即有  $\text{sign } \mathbb{E}[\widehat{D}_g] = \text{sign } D$ : 無標籤估計至多低估信任, 不會判錯符號。

此恆等式在翻轉由信心本身造成時失效, 典型情形即自信回音。此時「多數正確且  $D < 0$ 」與「多數因自信回音而錯誤且  $D > 0$ 」兩種情形的可觀測分布完全相同 (可視為 [10] 中雙根歧義在單通道情形的對應), 因此任何無標籤保證必然附帶條件; 本文如實陳述此限制。

## 5.3 去衰減與警報

每題做  $R = 20$  次隨機對半分割, 計算兩半多數決的一致率  $\alpha$ 。在含  $k$  個有效錯誤選項 (以逆 Simpson 指數估計) 的單硬幣模型下,  $\alpha = p^2 + (1-p)^2/k$ , 反解得  $p = [1 + \sqrt{1 - (k+1)(1 - k\alpha)}]/(k+1)$ 。去衰減時將  $\widehat{D}_g$  除以  $2p-1$  的自助法上界 (95%, 下限 0.2) 而非點估計, 故僅可能低估放大倍率。另設四項警報, 任一觸發即令  $\gamma = 0$ : 重複塌縮 (Kish 比中位數低於 0.5)、符號感知的 margin 去耦檢定、split-half 二次式的根歧義, 以及有效題數不足。其中 margin 去耦警報必須以估計的信任方向為條件: 若忽略符號、一律檢查「多數方的平均  $\varphi$  是否最高」, 則所有良性的負相關通道都會誤觸發。這個缺陷是開發過程中實際遭遇、診斷並修正的, 相關行為已由公開測試固定。顯著性閘門作用於原始統計量  $z$  (命題 4 保證其符號無偏), 調節則作用於去衰減後的數值。另提供半無標籤模式: 僅自約 50 筆 dev 標籤取符號並送入管線, 同時僅停用代理符號警報, 即可以極低的標註成本規避上述歧義。

## 六、異質性：不可能性與出路

### 6.1 i.i.d. 耦合下逐題自適應不可行

設  $\kappa_q \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 0.6^2)$  且無可觀測共變量。

**命題 5 (自我增強)。**對任何單調遞增的奇函數  $h$ ，逐題規則  $\gamma_q = h(\widehat{D}_q^g)$  在兩個分支上都增強多數決： $\widehat{D}_q^g > 0$  時上調自信軌跡的權重，而這些軌跡與多數方一致； $\widehat{D}_q^g < 0$  時上調不自信軌跡的權重，而這些軌跡同樣屬於多數方。實驗中，此類規則與 SC 在 97.5% 的題目上給出相同答案，其餘翻轉為淨損失（每 400 題翻對 1 題、翻錯 9 題）。

**備註 (贏家詛咒)。**這是目前實驗架構中的量測，不是定理：在  $|D_q| > 0.3$  且多數決錯誤的題目（即翻轉才可能獲勝的題目）上，一致性統計量的符號僅 4% 與真實符號一致。

**命題 6 (兩世界不可辨識)。**令  $w_1 = \{\kappa > 0, \text{少數方正確}\}$ ， $w_2 = \{\kappa < 0, \text{多數方正確}\}$ 。分別依兩種真值計算時， $D^{w_1} = -D^{w_2}$ ，因此 TACT 使用的統計量無法排序這兩個世界。當題目恰有兩個答案叢集時，兩者的  $(a, c)$  分布完全相同，任何無標籤方法都無法區分。若有三個以上且各自有實質人數的叢集，兩個分布便不再相同： $w_1$  只有正確的少數叢集帶高信心， $w_2$  則是每個非多數叢集都帶高信心；前兩個叢集上的分布相同，第三叢集的條件信心分布則能將兩者分開，數值驗證為 KS  $p < 10^{-15}$ 。所以不可能性只在池實質為二元時成立。自信回音格中有 88% 的題目在  $K = 15$  下沒有第三個叢集，正落在這個範圍內；TACT 與現有已發表方法都沒有利用剩下的訊號，這仍是開放問題。

因此逐題最佳結果（本實驗為 0.973）不可達成，合理的行為是退回全域估計。TACT 的死區恰好如此：在 i.i.d. 情境中，所有變體均回傳與 SC 位元層級相同的結果（不一致配對數為零）。

### 6.2 TACT-group

實務上的異質性多由可觀測共變量索引，例如領域或題型。當  $\kappa$  依群組標籤而定時，按群組執行估計器即可使每個群組落在第四、五節的作業範圍內；dev 樣本少於 30 題（無標籤情形少於 60 題）的群組退回全域估計。由命題 5、命題 6 與贏家詛咒的量測可知，此退回並非便宜行事，而是唯一站得住腳的預設。

## 七、實驗設定

**實驗架構。**叢集混合 oracle 逐題生成至多  $K_{\max} = 20$  條快取軌跡，內容包括答案、依式 (3.2) 生成的信心，以及兩種相似度通道；所有方法重放相同的軌跡池，以配對方式比較並採精確 McNemar 檢定。投票預算  $K = 15$ ；掃描實驗每格 400 題，群組研究 600 題；dev 分割取 200 題（主要設定）與 50 題（小型 dev 設定）。

**實驗情境。**耦合掃描  $\kappa \in \{-0.6, \dots, +0.6\}$ ；三種嚴格單調的信心失真（向 0.5 壓縮、過度自信 sigmoid、四次幂），依構造保序，故辨別力完好而校準全毀；i.i.d. 異質性 ( $\kappa_q \sim \mathcal{N}(0, 0.6^2)$ )；共變量結構異質性（三群組， $\kappa$  分別為  $+0.6/0/-0.6$ ）；以及自信回音毒化（錯誤叢集以信心 0.95 逐字重複）。

**基線。**SC；CISC-power ( $\gamma \in \{0.25, \dots, 4\}$ )；CISC-devT，即已發表的 dev 校準協定（於 dev 上選取正向網格）；二元 ECE 閘門；SignGrid-dev，最強的簡單基線（於 dev 上選取帶符號指數網格）；另以帶符號固定指數的測試集最佳值作為上包絡參考。群組研究加入自我參照的逐題方法作為陰性對照，並以逐題連結最佳值為理論上限。

**預先登記的證偽準則。**判定規則在此明確寫出，因為這套協定本身即為本文的一項貢獻。每項證偽準則為該格 400 題上的精確配對 McNemar 檢定（單尾  $\alpha = 0.05$ ），並以 8.6 節的 seed 層自助法為第二道閘門：單格檢定顯著且跨 seed 區間不含零，證偽準則才成立。單格檢定在此樣本數下對抗強基線的檢定力不足，這正是設第二道閘門的理由；早先固定的  $\tau = 0.02$  容差僅保留為表格中的報告便利，不再作為判定依據。F1:  $\kappa = +0.6$  時 TACT-dev 低於最佳固定  $\gamma$  的 CISC 超過  $\tau$ 。F2: 任一變體在掃描的任何位置低於 SC 超過  $\tau$ 。F3: 無標籤變體的掃描平均未能勝過 ECE 閘門。F4: CISC-devT 或 SignGrid-dev 在所有情境（含失真、異質性與小型 dev）都落在 TACT-dev 的  $\tau$  之內。F4 是最需要這套規則的一項：單格上 TACT



減 SignGrid 的比較在掃描任何位置都達不到顯著（最小  $p = 0.08$ ，位於  $\kappa = +0.1$ ），是十 seed 的自助法才把中段落差判定為系統性。只報單 seed 檢定的協定會把中段誤判為平手。




Figure 2: 圖 2: 信心使用效率上的主要結果。TACT-dev 與無標籤的 TACT-LF 全程貼近帶符號最佳值；CISC-devT 與 ECE 閘門在  $\kappa < 0$  的整個區間停留在 SC 基準線。

## 八、結果

表 1: 耦合掃描 ( $K = 15$  準確率；每格 400 配對題；dev  $n = 200$ )。既有方法在整個負半軸停留在 SC 基準線。

| $\kappa$ | SC   | ECE  | devT  | SignGrid | TACT-dev     | TACT-LF      | oracle |
|----------|------|------|-------|----------|--------------|--------------|--------|
| -0.6     | .762 | .762 | .762  | 1.000    | <b>1.000</b> | <b>1.000</b> | 1.000  |
| -0.4     | .805 | .805 | .805  | 1.000    | <b>1.000</b> | <b>1.000</b> | 1.000  |
| -0.2     | .750 | .750 | .750  | .985     | .975         | .975         | .985   |
| -0.1     | .750 | .750 | .750  | .915     | .900         | .890         | .915   |
| 0.0      | .745 | .745 | .760  | .760     | .745         | .745         | .772   |
| +0.1     | .777 | .777 | .932  | .932     | .907         | .907         | .932   |
| +0.2     | .760 | .760 | .985  | .985     | .978         | .978         | .985   |
| +0.4     | .785 | .785 | 1.000 | 1.000    | <b>1.000</b> | <b>1.000</b> | 1.000  |
| +0.6     | .780 | .780 | 1.000 | 1.000    | <b>1.000</b> | <b>1.000</b> | 1.000  |

### 8.1 帶符號恢復：有標籤與無標籤

表 1 與圖 2 為掃描結果，可歸納為三點。其一，既有方法在  $\kappa < 0$  從未離開基準線：CISC-devT 的網格僅含正向指數，ECE 閘門則始終未開啟（掃描中 dev ECE 介於 0.10 至 0.80，而通道在兩端的辨別力其實是完美的）。其二，無標籤變體與 200 標籤變體幾乎逐點相同；在  $\kappa = -0.6$  處，原始一致性統計量為  $\widehat{D}_g = -0.81$ 、 $z = -17.6$ ，命題 4 的符號保證如預期成立，方法在零標籤下達到 1.000。其三， $\kappa = 0$  時死區使  $\gamma$  精確為零，對 SC 的配對準確率差恆等於零；「不劣於」在此被「完全相同」取代。

推導出的指數實際上在哪裡起作用。撐起頭條 1.000 的四格 ( $\kappa = \pm 0.4, \pm 0.6$ ) 都是  $\widehat{D}$  飽和的格子：連結在七個飽和格上回傳的未截斷  $\gamma^*$  介於  $-8.4$  到  $+12.1$  之間，實際進入投票的是上限  $\gamma_{\max} = 4$ 。在那裡起

作用的是符號，不是推導出的幅度。反過來，在  $\kappa = \pm 0.1, \pm 0.2$  這四格，推導值嚴格落在上限之內 ( $|\gamma|$  介於 1.10 到 2.91)，TACT-dev 四格全數落後 dev 選取的帶符號網格 (0.900 對 0.915; 0.907 對 0.932; 0.975 對 0.985; 0.978 對 0.985)。合起來讀：相對已發表協定，優勢很大，且來自「能夠表達符號」這件事本身；相對帶符號網格，這個解析映射在這些格子上並不更會挑幅度。它勝過網格之處在別的地方，即 C4 點名的三種情形；而內插本身唯一真正付錢的地方是自信回音， $\gamma = -1.198$  落在網格點之間，勝過網格最佳的  $\gamma = -1$  (0.615 對 0.568)。

表 2：對抗情境 ( $K = 15$  準確率)。「oracle」為原始值權重策略在測試集上的最佳結果；單調壓縮下排名不變性勝過該家族全體。

| 情境          | SC   | devT  | SignGrid | TACT-dev     | TACT-LF      |
|-------------|------|-------|----------|--------------|--------------|
| 單調壓縮        | .775 | .963  | .963     | <b>1.000</b> | <b>1.000</b> |
| 單調過度自信      | .775 | 1.000 | 1.000    | <b>1.000</b> | <b>1.000</b> |
| 單調四次幂       | .775 | 1.000 | 1.000    | <b>1.000</b> | <b>1.000</b> |
| 異質 (i.i.d.) | .765 | .765  | .765     | .765         | .765         |
| 自信回音        | .190 | .190  | .568     | <b>.615</b>  | .190†        |

† 警報觸發，方法拒絕離開 SC；此即命題 4 條件保證的預期行為。

## 8.2 原始值失效處的排名不變性

單調壓縮下 (表 2、圖 3)，所有信心值集中於 0.5 附近，任何  $c^\gamma$  形式的權重都近乎均勻，原始值策略即使取測試集最佳也僅達 0.963；TACT 的排名分數不受失真影響，兩個變體均達 1.000。自信回音情境中，dev 標籤揭露了反轉現象 (信心高者反而錯誤)，TACT-dev 以  $\gamma = -1.20$  反制，取得全場最佳的 0.615，為 SC 基準線的 3.2 倍；無標籤情形下重複塌縮警報觸發，方法拒絕行動。由命題 6 可知，該格 88% 的題目實質為二元、命題所指出的逃逸口在其上不存在，因此無標籤方法對符號的任何判斷都不優於隨機，宣稱能夠判斷才是真正的錯誤。




Figure 3: 圖 3：對抗情境。虛線為原始值權重的測試集最佳。左側各組顯示排名不變性在壓縮下勝過整個原始值家族；最右側顯示有標籤變體反制自信回音，無標籤變體則觸發警報並拒絕行動。

### 8.3 異質性

表 3 與圖 4 為群組研究結果。在共變量結構情境中，逐群組 TACT 恢復了各群組的帶符號耦合（dev 為  $\{+4.0, 0.0, -4.0\}$ ，無標籤為  $\{+2.0, 0.0, -2.0\}$ ， $\kappa = 0$  的群組正確落入死區），並突破了束縛所有全域策略的基準線：無標籤變體達 0.923，與逐題連結最佳值僅差 0.023，且在 600 題中對 SC 無任何配對損失（ $+83/-0$ ， $p = 2.1 \times 10^{-25}$ ）。i.i.d. 情境中，所有方法都以零不一致配對停留在基準線，含自我參照的陰性對照在內：它無法勝過它自己所導出的那個多數決。這個對照正是命題 5、命題 6 與贏家詛咒量測的實證呈現，而它現形的地方是群組格——即使拿到逐群組估計器所利用的同一個共變量，它也只到 0.787，相對 0.785 的基準線是 600 題裡的兩題。

兩個 arm 在此格落在彼此的 seed 雜訊之內（單 seed 為 0.923 與 0.927，五 seed 平均各為  $0.929 \pm 0.015$ ）。一個自然的解釋是兩者指數上限不同，但消融實驗否決了它：把上限掃過  $\{1, 2, 3, 4, 6, 8\}$ ，兩個 arm 都完全不動（散布皆為 0.0000），可見上限在這一格不承重，差異就是抽樣變異。這一條如實保留：本文先提出一個歸因，又由自己安排的後續檢查把它推翻。

表 3：異質性研究（600 配對題； $K = 15$ ）。

| 方法                     | 群組結構        | i.i.d. |
|------------------------|-------------|--------|
| SC（基準線）                | .785        | .752   |
| TACT 全域（dev）           | .785        | .752   |
| TACT-group（dev）        | <b>.927</b> | .752   |
| <b>TACT-group（無標籤）</b> | .923        | .752   |
| 自我參照逐題法（陰性對照）          | .787        | .752   |
| 逐題連結最佳值（上限）            | .947        | .973   |




Figure 4: 圖 4：結構化與 i.i.d. 異質性的對照。左：具可觀測共變量時，逐群組 TACT（無標籤）自 0.785 基準線逼近逐題最佳值，且對 SC 零損失。右：可證明封閉的 i.i.d. 情境，所有方法停留在基準線，含陰性對照在內。

## 8.4 小型 dev 集與證偽結果

dev 縮減至 50 題時結論不變 ( $|\kappa| = 0.6$  仍為 1.000,  $-0.2$  仍為 0.978): 考慮標準誤的收縮使方法平滑退化, 而非驟然失效。四項證偽準則全數通過: F1 (1.000 對 1.000)、F2 ( $\kappa = 0$  位元層級相同, 其餘位置未低於 SC 超過預先登記的 0.02 容差)、F3 (掃描平均 0.944 對 0.768)、F4 (兩個網格基線在失真與回音格分別落後 0.037 與 0.047, 且都無法在無標籤下運作)。

須說明的是配對檢定的實際狀況: 在單一 seed 上, 對 SignGrid-dev 的檢定在任何位置都不顯著 ( $\kappa = -0.2$ : 不一致配對 3/7, 精確  $p = 0.34$ ;  $\kappa = +0.1$ : 8/18,  $p = 0.08$ ), 是 8.6 節的十 seed 區間才確立中段落差。相對 SignGrid-dev 的誠實邊際在同質掃描上很窄——TACT 在中段甚至落後 0.007 至 0.025, 這是收縮的預期代價——淨優勢正好集中在事前登記的三處: 失真 (+0.037)、回音 (+0.047), 以及網格無法執行的無標籤運作。

## 8.5 實作的驗證

本文第四至六節的每一項主張都是數學性質而非經驗趨勢, 因此公開程式碼為每一項設定可執行的測試; 測試套件共 102 項, 涵蓋 TACT 與後續工作。下表列出命題與測試的對應——若性質不再成立, 對應測試即失敗。

表 4: 測試套件驗證的內容。本文每一項命題都有可執行的對應測試; 反向測試會刻意讓已否決方案失敗, 避免日後的迴歸錯誤悄悄將它們恢復。

| 主張                | 證據                                                                                                          |
|-------------------|-------------------------------------------------------------------------------------------------------------|
| 命題 1 (精確 SC)      | 200 個隨機池, 含平手處理完全相同; $D = 0$ 下死區觸發率 $> 70\%$                                                                |
| 命題 2 (精確 CISC)    | 100 個池, 得票份額完全一致                                                                                            |
| 命題 4 (衰減)         | $\rho \in \{.1, .25, .4\}$ , 絕對誤差 .06                                                                       |
| 命題 5、命題 6 與贏家詛咒量測 | 97.5% 與 SC 一致; 符號僅 4% 相符; 兩世界邊界雙向釘住 (二元池不可辨識; 出現有實質人數的第三叢集則可分離, KS $p < 10^{-10}$ )                         |
| 排名不變性<br>估計器內部    | 3 種失真 $\times$ 100 個池<br>置換零假設變異數 (3,000 次抽樣, 10% 容差)、JS-EB 恆等式精確至 $10^{-12}$ 、連結式相對誤差 $10^{-9}$ 、置換不變性迴歸測試 |
| 已否決方案             | Kish ESS 與 SAFE-under-VoI 保證各有一項斷言其失敗的測試                                                                    |

其中兩項值得說明。置換不變性測試是在一次缺陷之後補上的: 當時快取鍵讓測試本身通過, 而估計器實際上具有高達 0.10 的順序依賴; 現行版本直接呼叫內部常式以繞過快取。最後一列則是反向測試, 斷言已否決方案 (Kish 有效樣本數公式, 以及「出貨預設遵守 SAFE 停止保證」的說法) 確實失敗, 以防後續修改悄悄將其復原。

## 8.6 一個 harness 假象, 以及跨 seed 的離散度

對合成結果有兩處修正, 都是把原本的單 seed 量測重跑之後才發現的。

平手處理在白送分給 SC。產生器在每一題都把正確答案編碼為 0, 而  $\text{argmax}$  的平手偏向最小索引, 因此任何得票平手的題目, 純 SC 依構造就選對: 近乎平手的題目上 SC 拿 67.7%, 隨機平手處理只有 50.4%, 而  $K = 15$  時有 31.8% 的題目是平手。任何把權重擾動離開整數的方法都會失去這份補貼, 所以這個假象同時抬高了基線並懲罰了本文方法。它還製造了一個假的證偽事件:  $\kappa = 0$  時 TACT-dev 十 seed 平均 0.797、SC 為 0.818, 觸發 F2; 但當時的指數其實都是  $|\gamma| \leq 0.05$ ——被動到的是那些平手處理改變了的

題目，不是被指數重新加權的題目。現在答案編碼逐題置換。假象移除後，兩者在死區該成立的地方精確重合： $\kappa = 0$  兩法同為 0.745，異質  $\kappa$  兩法同為 0.765（十 seed 平均分別為 0.758 與 0.768，每個 seed 的不一致配對皆為零），死區的行為與命題 1 所述一致。本文所有合成數字都是修正後重跑的結果。

離散度。每格十個 seed、每 seed 400 配對題，對 seed 做自助法。兩端極穩定，第三位小數以內 ( $|\kappa| \geq 0.4$  為  $1.000 \pm 0.001$ )。中段相對 SignGrid-dev 的落差雖小但是真的，不是雜訊： $\kappa = -0.2$  為  $-0.013 [-0.017, -0.009]$ 、 $-0.1$  為  $-0.016 [-0.024, -0.009]$ 、 $+0.1$  為  $-0.012 [-0.018, -0.005]$ 、 $+0.2$  為  $-0.013 [-0.019, -0.008]$ ，四者  $p < 0.001$ 。本文宣稱有優勢的地方同樣是真的：單調壓縮  $+0.032 [+0.027, +0.037]$ ，自信回音  $+0.048 [+0.037, +0.059]$ 。唯一在修正後改變符號的格子是異質  $\kappa$ ，由損失變為  $+0.011 [0.000, +0.031]$ 。只報單一 seed 會同時藏住這個假象，以及「中段落差是系統性的」這個事實。

## 8.7 真實軌跡驗證

以 Claude Haiku 4.5 為凍結模型做真實軌跡驗證：100 題 (GSM8K [23] 與 CommonsenseQA 各 50 題)，每題 12 條獨立思維鏈與口頭信心（共 1,200 條軌跡），於  $K = 12, 40/60$  的 dev/test 分割下評測。結果有四項發現。

(a) 校準與辨別的區分在真實資料上反轉，而 TACT 讀對了。此通道在傳統意義上校準極佳：ECE = 0.016，遠低於 0.10 的閘門，因此二元 ECE 閘門會開啟並把通道交給 CISC 使用。然而實測的題內辨別度為  $\widehat{D} = -0.219$ 、SE = 0.176 ( $z = -1.24$ )：沒有可用訊號，而僅有的一點傾向還指向錯誤方向（數學  $-0.515$ 、常識  $-0.173$ ，兩組皆為負）。這與合成情境恰成鏡像——在那裡 ECE 錯誤地關閉了一條具辨別力的通道（第三節），在真實資料上它卻錯誤地開啟了一條不具辨別力的通道。校準度在兩個方向上都無法反映投票效用，而帶符號的辨別度統計量正是區分兩者的依據。

(b) 死區觸發，且代價恰好為零。由於  $|z| < \nu$ ，TACT-dev、TACT-LF 與 TACT-group 一律回傳  $\gamma = 0$ ，在全部測試題上與 SC 位元層級相同（不一致配對  $+0/-0$ ， $p = 1$ ），所有方法同為 0.917。第九節預先登記的零方向預測，在真實資料上得到確認：通道沒有訊號時，方法不收取任何代價。

(c) 真正的限制是基準飽和，而非估計器。軌跡層級準確率在 GSM8K 為 0.958、CommonsenseQA 為 0.847，因此 100 題中僅有 12 題同時含有正確與錯誤軌跡——而這是題內秩統計量唯一能利用的題目。估計器並非設計上功效不足，是基準本身沒有讓模型面臨足夠的真實不確定性。要在強模型上暴露非零耦合，需要更難的題庫，而非每題更多軌跡。

(d) 口頭信心高度集中。兩個數值 (0.99 與 0.95) 占全部回報的 49%，在許多題目上觸發了 4.1 節的同分安全路徑。

(e) 棄權是一個量測，而且在這裡很脆弱。一個永遠不動手的規則會原封不動重現 (b)，所以這場實驗本身完全無法區分「安全機制有效」與「根本沒有訊號」。對同一批快取池做三次重放，能多分開一些。穩定性：重抽題目，dev 閘門在 50.4% 的重抽樣本中會開啟—— $|z| = 1.24$  對  $\nu = 1.28$ ，這次棄權是 3% 的差距，不是對證據的判讀；無標籤閘門是 16.2%——但 (f) 會顯示這個數字只描述顯著性閘門本身。特異度：把信心在題內置換（保留真實邊際、同分結構、池組成與難度，只打斷耦合），誤開率為 18.4% 對名目 20%（無標籤 1.6% 對 2%），零假設  $z$  的 mean  $-0.002$ 、SD 0.954。死區的零假設行為因此是在真實基質上校準正確，而不只是在它自己推導所本的生成器上——這是本節唯一一項「機制真的在做事」的證據。代價：忽略閘門強制動手，推導出的  $\gamma = -0.40$  會得到 0.933 ( $+1/-0$ )，真值 oracle 在  $\gamma = -1.25$  達到 0.950，天花板是兩題。兩者都遠不到顯著，所以這個基質在要緊的意義上確實是零；但估計器推導出的符號正是 oracle 想要的符號，而 (b) 該讀成「在這個  $n$  下量不出代價」，不是「已證明棄權是對的」。

(f) 這個閘門在這裡本來能偵測到什麼。(e) 量的是特異度；敏感度需要一條已知強度的通道，所以把一條植入同一批池——真實答案、難度、重複結構全部不動，只替換信心向量，並以真實的對錯型態為條件。只植入估計器自己的位移模型什麼也證明不了（就是第九節提過的不變群陷阱），所以掃了四個生成族：高斯位移；同樣的位移換 Laplace 雜訊（破壞連結的常態性假設、保留  $D$ ）；把最高信心位強制放到正確軌跡上的秩集中通道；以及只動變異數、有資訊但無符號的通道。每格 40 個 seed，四個結果。其一：閘門的操作特性是實現  $|\widehat{D}|$  的函數、與生成族無關——半功率點約在  $|\widehat{D}| = 0.247$ （高斯）與 0.208（Laplace），全

功率分別在 0.49 與 0.56，推導出的指數則分別自 0.83 與 0.95 起吃下全部 oracle 增益；在高斯的那兩個門檻上，Laplace 族已達 0.975 功率與 0.98 capture——偵測是秩泛函的性質、不是生成器的性質，連結也在常態性被破壞下存活。(a) 量到的真實通道  $|\widehat{D}| = 0.219$  正好落在半功率地板上：(e) 的擲硬幣，就是這條操作特性曲線的另一種說法。其二：只要閘門開啟，符號在任何族的任何格都沒錯過。其三：適用範圍的邊界是真的。秩集中通道在全強度下也只到  $|\widehat{D}| \leq 0.183$ ——合併的成對統計量幾乎看不見集中在單一秩位置的資訊——推導增益趨近零，而真值指數能拿  $+0.039$ ；無符號通道依構造不可見，閘門在其上正確維持名目誤開率。其四，一個缺陷：無標籤 arm 在任何格都不動手，即使通道近乎完美、題數門檻降到 1 也一樣，因為 100 題中 85 題全體一致，margin 閘門的 40 分位切點等於 1.0，沒有任何題目能同時滿足「margin  $\geq 1.0$ 」與「至少兩個相異答案」。所以 (b) 裡它的棄權是結構性的，不是對通道的判讀；在飽和基質上，分位數閘門需要改用絕對切點。

適用範圍：單一模型、兩個基準、 $K = 12$ 。此結果乾淨地證實了零方向預測與校準—辨別論點，但並非 TACT 在真實軌跡上提升準確率的證據；發現 (c) 指出了該怎麼辦，8.8 節就去做了。

## 8.8 更難題目上的確認實驗

發現 (c) 預測：在飽和基準上量到為零的通道，換到模型真正不確定的題目上應該就量得到。預先註冊的後續實驗檢驗這個預測：MATH level-5 共 119 題 [24][25]，每題 16 條軌跡，同一個凍結模型；符號集 30 題、評估集 89 題，兩者在任何軌跡收集之前就從註冊清單切分完成；五項假設 H1–H5 事先固定。

通道是真的。評估集上  $\widehat{D} = +0.250$ 、 $SE = 0.098$ ，故  $z = +2.54$ ，H1 通過。這是真實軌跡上首次證實口頭信心攜帶正向的題內辨別度；同一量測在 GSM8K/CommonsenseQA 上是  $-0.219$  ( $z = -1.24$ )。

終點對任何方法都不可通過。實際跑出來的基質再次飽和：每軌跡準確率 0.819、SC 為 0.888、決定性分層只有 89 題中的 10 題，其中正解在池內的僅 4 題。池內 oracle 因此最多  $+4/-0$ ，精確單尾  $p = 0.0625$ 。H2 失敗，但它對每一種可想像的聚合方法（包含完美方法）都失敗，所以這是基質的性質，不是估計器的性質。

棄權行為如設計運作，但原因是兩個。TACT 在兩條無標籤路徑上都回傳  $\gamma = 0$ ，而這兩次失敗值得分開講。完全無標籤那條被 E4 與 E2 擋下：只有 13 題能帶著有變異的偽標籤通過 margin 閘門，而門檻是 50；把閘門的分位數一路放寬到 0 也只到 39——所以這條路徑在這個基質上、任何通道強度下都測不到。半無標籤那條被完全不同的東西擋下：它 30 題的符號集只到  $z = +0.83$ ，而門檻是  $|z| > 1$ ；同一個基質的評估集卻到  $z = +2.54$ 。那是符號集的檢定力不足、不是通道不存在，解法是加標籤而不是換方法。投票因此與 SC 位元等同，同為 0.888 (H3、H4 通過)。硬要動手的代價在同一張表上：best-single-confidence 這個「永遠相信通道」的平凡基線輸掉 4.5 分，落在 0.843。E4 是一個題數供給條件、不是對通道的判讀；而 (f) 顯示它有兩條路徑：在 8.7 節那批飽和池上，margin 閘門的分位切點退化成 1.0、過閘集合對任何通道都是空的；這裡的切點是 0.875、集合非空，所以警報回報的是相對門檻的真實供給不足，不是崩潰。只有前者是缺陷。

表 5：確認實驗，MATH level-5 評估集 (89 題， $K = 16$ )。所有方法重放同一批快取池。因為未收集推理文字，重複通道失效，故 dedup-SC 依構造與 SC 相同。

| 方法                          | 準確率   | 相對 SC 淨值 |
|-----------------------------|-------|----------|
| SC / dedup-SC / CISC-linear | 0.888 | —        |
| TACT-LF                     | 0.888 | +0/-0    |
| TACT-semi-LF                | 0.888 | +0/-0    |
| best-single-confidence      | 0.843 | +1/-5    |
| 池內 oracle (天花板)             | 0.933 | +4/-0    |

這次實驗還帶出一個超出 TACT 的注意事項：量到的難度取決於收集協定。每次呼叫 30 題的探測測得 level-5 多數決正確率 0.40，每次呼叫 15 題的確認收集在同一難度層卻測得 0.888。只要軌跡是分批收集

的，批次大小就該進實驗紀錄。

## 8.9 可作用的分層有多寬？

兩次實驗都因同一個理由未達終點，那就值得直接量那個理由。定義窗口為「多數決錯且正解在池內」的題目比例：這是任何無標籤聚合方法的天花板，窗口以外的題目它什麼都改不了。

窗口在跨兩個領域的五個基質上量測（表 6）。程式碼生成這一側有可執行測試提供逐樣本真值，照理窗口該更寬：40 題 LeetCode Medium/Hard [26] 各解 8 次，對基準自身的隱藏測試套件評分，基線取探測輸入上的最大行為叢集（只用輸入，不用期望輸出）。窗口是  $3/40 = 7.5\%$  ( $CI_{95}$  2.6–19.9%)——比無標籤 QA 寬，但同一個數量級，形態也相同：30 題飽和、7 題能力牆、3 題可救援，即 75/17.5/7.5%。加預算打不開它：7 個能力牆題目在 224 次追加嘗試中零個正確（每題通過率 95% 上界 0.088），外推  $\text{oracle}@N$  顯示窗口在  $N = 32$  就飽和。

表 6：跨基質的可作用分層，全表採同一組定義：決定性 (Dec.) 為多數決錯誤的題目比例，窗口 (Win.) 為既決定性、正解又在池內的比例，兩者皆為百分比。窗口是任何無標籤聚合方法的天花板。† 為本文量測；HumanEval+ / MBPP+ 由已發表的 oracle 減選擇器表格重算，該來源只報窗口。題目變難時決定性比例上升，窗口卻沒有：它們從飽和直接進入能力受限。MATH L5 這一系列的分母是整份註冊清單 119 題（被量測的對象是基質本身）；8.8 節引用的則是切出符號集之後剩下的 89 題評估集上的同一組量（10 題與 4 題，即 11.2 與 4.5）。最後一列是同一個 MATH L5 基質在 8.10 節預算操作下的結果，不是第六個基質；全文引用的 2.5–7.5% 區間是上面那五列的範圍。

| 領域      | 基質                 | 決定性  | 窗口   |
|---------|--------------------|------|------|
| QA      | GSM8K / CSQA†      | 9.0  | 4.0  |
| QA      | MATH L5†           | 7.6  | 2.5  |
| QA      | AIME / AMC†        | 23.3 | 3.3  |
| 程式碼     | HumanEval+ / MBPP+ | —    | 3.6  |
| 程式碼     | LeetCode Med/Hard† | 25.0 | 7.5  |
| QA，預算受限 | MATH L5†           | 18.5 | 11.8 |

這些數字附帶一個必要的前置檢查，少了它結論會整個反過來。評分 harness 在任何候選被評分之前，先對基準自身的參考解驗證：180 題中 178 題在沙箱的資源限制下通過。這不是形式：一個資源限制被主機直接拒絕的沙箱會讓 100% 的執行失敗，而這種狀況呈現出來的樣子是「候選解不通過」，不是錯誤。用執行評分的研究都該報告自己的參考解通過率，理由和報告校準曲線一樣：沒有它，壞掉的 harness 和能力牆長得一模一樣。

## 8.10 第三軸：推理預算

降低每樣本準確率的辦法不只是把題目變難。限制推理預算同樣能降低它，而且正解仍留在模型的能力範圍內——這正是決定性分層需要、而難度給不了的組合：題目變難時，它們從飽和直接跨進能力受限，中間不停留。一組配對實驗在同樣的 119 題、同一個模型、同一個  $K$  上檢驗這件事，差別只在指示模型不要寫任何計算過程直接作答。

這個操作在它自己宣告的檢查上比預先登記的要弱（每樣本準確率  $0.853 \rightarrow 0.781$ ，未達要求的 0.10 降幅），而且正解沒有離開池 ( $0.950 \rightarrow 0.933$ )，所以以下屬於探索性結果。之所以要報，是因為這個限制並非均勻地拉低準確率，而是把題目搬過了多數決邊界：SC 從 0.924 掉到 0.815，窗口從 2.5% 撐開到 11.8%（對窗口成員資格做配對精確 McNemar, 13 進 2 出,  $p = 0.0037$ ），而且通道變強了， $\widehat{D}$  從 +0.229 ( $z = 2.69$ ) 升到 +0.398 ( $z = 6.76$ )。被迫不寫過程直接答時，模型的信心確實跟著「這題我剛好對不對」在走。



這是全文量到最寬的窗口，也是唯一一個池內 oracle 真的越過終點的基質（+9/-0，決定性分層 17 題上  $p = 0.002$ ）。即便如此 TACT 仍回傳  $\gamma = 0$ ：通過 margin 閘門的只有 12 題，低於 30 題的門檻，E4 觸發——這是同一個題數供給條件，分位切點為 0.875、過閘集合同樣非空，並不是 (f) 所報告的那個退化情形。這個棄權是可檢驗的，不是品味問題，而且它沒有付出代價。若改用真值標籤估計  $\gamma$ ——一個任何可部署方法都拿不到的上界——最好的結果是  $\gamma = 1$  時的 +4/-1 ( $p = 0.19$ )，而推導值  $\gamma = 0.670$  給出 +3/-1。所以真正卡住的並不是窗口這道關。即使窗口撐到 11.8%、oracle 有能力轉換 9 題，信心加權能碰到的不到其中一半，而且沒有任何一種可達設定達到顯著。

## 九、討論與限制

證據涵蓋到哪裡、沒涵蓋到哪裡。本文的準確率主張全部來自合成 oracle，其信心模型在同質格上正是估計器所量測的耦合形式。有三項設計選擇用來抑制循環論證，但其中第一項比看起來弱：異質性與回音確實落在估計器的工作模型之外，然而三個失真格依構造保序，因此落在 TACT 自身的不變群之內——通過它們，測到的是實作確實尊重一個它被設計成要有的不變性，而不是探測了一個未受檢驗的區域。另外兩項成立：機制恢復（ $\hat{D}$  是否追蹤  $\kappa$ ）與準確率屬於分開報告的兩類主張；基線能力範圍（圖 1）在方法存在之前就已量測並固定。8.7 與 8.8 節的真實軌跡實驗檢驗的是前提與棄權行為，兩項預測都成立：通道在飽和基準上為零、在競賽數學上為正，而死區在兩種情形下都讓投票與 SC 位元等同。它們不檢驗準確率主張，因為兩個基質上可作用的分層都不足以讓任何方法展示增益（8.9 節）。

標籤充足時優勢有限。若標籤充裕且信心尺度可信，dev 上選取的帶符號網格已能取得大部分效益；TACT 的價值在於無標籤情境、失真的信心尺度、小型 dev 集，以及端點性質的精確性。

無標籤保證附帶條件，以及越界之後的後果。命題 4 要求去重後  $\bar{\rho} < 1/2$ ，且自信回音造成的歧義屬於根本限制（命題 6）。後續工作實測了越過該邊界的後果，情況比「低估信任」嚴重得多：在改寫式錯誤多數情境中（主導的錯誤叢集語意緊密但不含逐字特徵，去重無從著手），多數決在多數題目上是錯的、 $\bar{\rho} > 1/2$ ，此時 TACT-LF 並非收縮向 SC，而是判錯符號、在  $\gamma = -2.0$  觸頂，準確率歸零（SC 地板為 0.340）。四個警報全部沒有觸發，因為 E1 依賴逐字重複，而此情境按構造不存在逐字重複。這是本方法最尖銳的未防護失效模式：保證是條件性的，該條件在無標籤下不可觀測，而現有診斷偵測不到它被違反。因此在「系統性錯誤多數」有可能出現的場合，實務上應將半無標籤模式（以約 50 筆標籤取符號）視為預設，而非可選的增強。另一個標準對策本文沒有試，但應該試：這個失效由一個語意緊密、而字面去重看不見的錯誤叢集驅動，而這正是語意等價分群 [27] 要塌縮的東西。把字面偽標籤換成語意偽標籤是最明顯的下一道防線，本文未予檢驗。

每群組單一指數。群組之內 TACT 僅輸出一個指數；由命題 5、命題 6 與贏家詛咒量測，群組內的逐題變異在缺乏進一步共變量時無法利用。

薄窗現象。8.9 節把這一類方法能作用的分層量在五個基質上都只有 2.5–7.5%，跨兩個領域，而且題目變難時不會變寬：它們從飽和直接進入能力受限。對本文的方法有兩個推論。其一，棄權不是保守的折衷而是唯一正確的預設，硬要動手的實測代價在兩個真實基質上都是負的（表 5 中 best-single-confidence 輸 4.5 分，而死區把 TACT 精確釘在 SC 地板上）。其二，合成 harness 上那個量級的聚合增益，在這種窗口寬度下用幾百題的基準根本量不出來——這也是本文的真實資料主張只限於前提（通道存在且帶符號）與棄權行為，不延伸到準確率的原因。要展示增益，需要一組多數決在 30–60% 題目上出錯、而正解仍在可及範圍的（模型、基準）組合；本文試過的組合沒有一組同時滿足這兩個條件。至於「窗口只在外部錨便宜的地方才變寬」這個看似合理的假設，8.9 節已直接檢驗並否定：可執行真值買到的是稍寬的窗口，不是另一個 régime。而 8.10 節顯示，就算把窗口撐到 11.8%，信心加權仍碰不到 oracle 能轉換的一半——窗口之外還有第二道關。

主動把窗口撐開。這個結果也點出本文沒有做、但最值得做的方向。難度會讓題目從飽和直接跳到能力受限，但 8.10 節的預算限制是把題目搬過多數決邊界、同時把正解留在模型能力之內——這正是決定性分層需要的組合；sampling temperature 是性質相同的第二個旋鈕，兩者本文都沒有掃。如果取樣 régime 是可控輸入而非基質的固定性質，問題就從「窗口有多寬」變成「哪一組解碼設定能把最多題目放進窗口、代價是多少準確率、而且信心通道在那裡還帶不帶符號」。預算那一組實驗把第一部分回答了一次，並且顯



示通道在限制下反而變強 ( $\widehat{D}$  從 +0.229 到 +0.398)，但這需要在不只一個基質上確認才能相信。一個會自己選解碼預算來最大化決定性分層、然後才聚合的方法，會是與本文不同的貢獻；而這裡的量測正是它值得一試的理由。

## 十、結論

TACT 將「該信任模型的信心到什麼程度」轉化為可量測、帶符號、考慮不確定性的純量，並在明確陳述且經測試的條件下，於零標籤情形恢復其符號。不過框住它的那個量測比估計器本身更重要：在兩個領域五個基質上，任何無標籤聚合方法能作用的分層只有題目的 2.5–7.5%，而在兩個真實基質上，連池內 oracle 都無法通過預先登記的終點。在這種區域裡，一個估計器有用的性質是知道什麼時候不要動手，而死區正是精確地做到這件事。

## 程式碼與資料可得性

全部程式碼、快取軌跡，以及每張表背後的 JSON artifact，均位於 <https://github.com/vito1317/adaptive-reasoning-consensus>。8.5 節的測試表由 `pytest` 於 commit 5f14b20 產生；合成結果由 `experiments/run_tact_eval.py` 產生，真實軌跡實驗由 `run_tact_hard_eval.py`，窗口量測由 `run_g1_window.py` 與 `run_g1_deepening.py`；發現 (e) 的三組棄權重放由 `run_abstention_identifiability.py` 產生，發現 (f) 的植入通道操作特性則由 `run_planted_sensitivity.py` 產生。每支腳本都會寫出其對應表格所引用的 artifact。圖 1 至圖 4 是 `experiments/make_paper_figures.py` 讀取同一批 JSON 後輸出的向量圖。

## 附錄：符號表

依首次出現順序排列。帶下標  $q$  的量是逐題的；除非有可用的群組共變量（第六節），估計器只輸出一個全域純量。

表 7：依首次使用順序排列的符號。帶下標  $q$  的量屬於逐題量；除非有可用的群組共變量（第六節），估計器只輸出一個全域純量。

| 符號                            | 意義                                                                    |
|-------------------------------|-----------------------------------------------------------------------|
| $q$ 、 $Q$                     | 題目索引；題目數                                                              |
| $m_q$ 、 $K$                   | 題 $q$ 可用的軌跡數；投票預算                                                     |
| $a_{q,i}$ 、 $a_q^*$           | 軌跡 $i$ 的答案；正確答案                                                       |
| $c_{q,i}$                     | 自我回報的信心，落在 $(0, 1)$                                                   |
| $y_{q,i}$                     | $\mathbf{1}[a_{q,i} = a_q^*]$ ；測試時不可觀測                                |
| $\bar{p}$                     | 正確軌跡的基礎率                                                              |
| $R_{q,i}$                     | $c_{q,i}$ 的題內中位秩（同分取平均）                                               |
| $\varphi_{q,i}$               | $R_{q,i}$ 的標準化 van der Waerden 分數；投票特徵                                |
| $\sigma_q$                    | normal scores 在題內的實測標準差                                               |
| $\gamma$ 、 $\gamma_{\max}$    | 投票指數；其上限（dev 為 4、無標籤為 2）                                              |
| $\hat{a}_q$                   | 回傳的答案                                                                 |
| $D_q$                         | 題 $q$ 內的 Somers' $D$ ，<br>$= 2 \text{AUC}_q - 1 = 2 \text{WQD}_q - 1$ |
| $N_q$                         | van Elteren 混合權重， $n_q^1 n_q^0$                                       |
| $\widehat{D}$                 | 合併後的帶符號辨別度                                                            |
| $\text{SE}_0$ 、 $\text{SE}_J$ | 精確 tie 校正零假設標準誤；刪一題 jackknife 標準誤                                     |
| $\text{SE}$                   | $\max\{\text{SE}_0, \text{SE}_J, 1/(2\sqrt{N})\}$                     |
| $\zeta$                       | $\widehat{D}/\text{SE}$ ；死區為 $ \zeta  \leq \nu$                       |

| 符號              | 意義                                          |
|-----------------|---------------------------------------------|
| $\nu$           | 顯著性下限 (dev 為 1.28、無標籤為 2.33)                |
| $\tilde{D}$     | 收縮後的辨別度, $\widehat{D}(1 - \nu^2/\zeta^2)_+$ |
| $z$             | $\Phi^{-1}((1 + \tilde{D})/2)$              |
| $M_q$           | 去重加權多數; 即偽標籤                                |
| $g_{q,i}$       | $\mathbf{1}[a_{q,i} = M_q]$                 |
| $\bar{\rho}$    | 多數決錯誤的成對加權機率                                |
| $\hat{\eta}$    | 估計的衰減量 $1 - 2\bar{\rho}$ (不是 $\bar{\rho}$ ) |
| $\alpha, k$     | split-half 一致率; 有效錯誤選項數                     |
| $E_1 \dots E_4$ | 四項警報; 任一觸發即令 $\gamma = 0$                   |
| $\psi$          | $E_2$ 背後的 margin 去耦統計量                      |
| $\kappa_c$      | oracle 中真實的信心—正確性耦合                         |
| $\lambda_q$     | i.i.d. 異質性下的逐題耦合                            |

## 參考文獻

- [1] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, “Self-consistency improves chain of thought reasoning in language models,” in *Proc. ICLR*, 2023. · PDF
- [2] K. Tian *et al.*, “Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback,” in *Proc. EMNLP*, 2023. · PDF
- [3] M. Xiong *et al.*, “Can LLMs express their uncertainty? An empirical evaluation of confidence elicitation in LLMs,” in *Proc. ICLR*, 2024. · PDF
- [4] S. Kadavath *et al.*, “Language models (mostly) know what they know,” arXiv:2207.05221, 2022. · PDF
- [5] A. Taubenfeld *et al.*, “Confidence improves self-consistency in LLMs,” in *Findings of ACL*, 2025, arXiv:2502.06233. · PDF
- [6] J. Kim, N. Yang, K. Min, and K. Jung, “Reliability-aware adaptive self-consistency for efficient sampling in LLM reasoning,” in *Findings of ACL*, 2026, pp. 21575–21590. · PDF
- [7] Y. Fu *et al.*, “Deep think with confidence,” arXiv:2508.15260, 2025. · PDF
- [8] X. Huang, S. Li, M. Yu, M. Sesia, H. Hassani, I. Lee, O. Bastani, and E. Dobriban, “Uncertainty in language models: Assessment through rank-calibration,” in *Proc. EMNLP*, 2024, pp. 284–312. · PDF
- [9] A. P. Dawid and A. M. Skene, “Maximum likelihood estimation of observer error-rates using the EM algorithm,” *J. Roy. Statist. Soc. C*, vol. 28, no. 1, pp. 20–28, 1979. · PDF
- [10] F. Parisi, F. Strino, B. Nadler, and Y. Kluger, “Ranking and combining multiple predictors without labeled data,” *Proc. Natl. Acad. Sci.*, vol. 111, no. 4, pp. 1253–1258, 2014. · PDF
- [11] Y. Li *et al.*, “Making language models better reasoners with step-aware verifier,” in *Proc. ACL*, 2023. · PDF
- [12] P. Aggarwal, A. Madaan, Y. Yang, and Mausam, “Let’s sample step by step: Adaptive-consistency for efficient reasoning and coding with LLMs,” in *Proc. EMNLP*, 2023, pp. 12375–12396. · PDF
- [13] Y. Li *et al.*, “Escape sky-high cost: Early-stopping self-consistency for multi-step reasoning,” in *Proc. ICLR*, 2024. · PDF

- [14] Z. Kang, X. Zhao, and D. Song, “Scalable best-of-N selection for large language models via self-certainty,” in *Proc. NeurIPS*, 2025, arXiv:2502.18581. · PDF
- [15] J. Whitehill *et al.*, “Whose vote should count more: Optimal integration of labels from labelers of unknown expertise,” in *Proc. NeurIPS*, 2009. · PDF
- [16] D. R. Karger, S. Oh, and D. Shah, “Iterative learning for reliable crowdsourcing systems,” in *Proc. NeurIPS*, 2011. · PDF
- [17] J. Lee, V. Ma, S. Zhao, Y. Nair, A. Spector, R. Cohen, and E. J. Candès, “FUSE: Ensembling verifiers with zero labeled data,” arXiv:2604.18547, 2026. · PDF
- [18] R. Ai, Y. Pan, D. Simchi-Levi, M. Tambe, and H. Xu, “Beyond majority voting: LLM aggregation by leveraging higher-order information,” arXiv:2510.01499, 2025 (已獲 ICML 2026 接受) . · PDF
- [19] P. van Elteren, “On the combination of independent two-sample tests of Wilcoxon,” *Bull. Int. Statist. Inst.*, vol. 37, pp. 351–361, 1960. · PDF
- [20] W. James and C. Stein, “Estimation with quadratic loss,” in *Proc. 4th Berkeley Symp. Math. Statist. Prob.*, 1961, pp. 361–379. · PDF
- [21] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965. · PDF
- [22] J. N. K. Rao and A. J. Scott, “The analysis of categorical data from complex sample surveys,” *J. Amer. Statist. Assoc.*, vol. 76, no. 374, pp. 221–230, 1981. · PDF
- [23] K. Cobbe *et al.*, “Training verifiers to solve math word problems,” arXiv:2110.14168, 2021. · PDF
- [24] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt, “Measuring mathematical problem solving with the MATH dataset,” in *Proc. NeurIPS Datasets and Benchmarks*, 2021. · PDF
- [25] H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, and K. Cobbe, “Let’s verify step by step,” in *Proc. ICLR*, 2024. (MATH-500 測試子集) · PDF
- [26] Y. Xia, W. Shen, Y. Wang, J. K. Liu, H. Sun, S. Wu, J. Hu, and X. Xu, “LeetCodeDataset: A temporal dataset for robust evaluation and efficient training of code LLMs,” arXiv:2504.14655, 2025. · PDF
- [27] L. Kuhn, Y. Gal, and S. Farquhar, “Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation,” in *Proc. ICLR*, 2023. · PDF