

TACT: 面向大型語言模型自我一致性投票的信任錨定信心調節

柯瑋宸 (Wei-Chen Ko, vito1317) — 獨立研究者

摘要

當凍結模型自我回報的信心在方向上校準正確時，信心加權自我一致性能勝過多數決。然而現有的加權方案一律是信心的單調遞增函數，因此反相關的通道會毒化投票；而二元校準閘門雖能在反轉下存活，代價是連帶捨棄仍具辨別力的訊號。TACT (Trust-Anchored Confidence Tempering, 信任錨定信心調節) 改由通道實測的帶符號題內辨別度推導投票指數：以帶題內叢集標準誤的混合 van Elteren Somers' D 為基礎，經正部 James–Stein 收縮，再經 Bayes 判別連結；在預設基礎率 $\bar{p} = \frac{1}{2}$ 下，整式化簡為 $\gamma = z\sqrt{2 + z^2}$ ，其中 z 為收縮後合併 AUC 的 probit。收縮死區之內，投票與純自我一致性位元層級相同。本文另提出無標籤變體，自一致性偽標籤估計符號，並在衰減恆等式下保證：只要多數決錯誤率低於二分之一，符號估計必為一致；越過該邊界後它會判錯符號，本文對此如實量測並報告。在合成 oracle 實驗中，此變體恢復了使所有已發表協定停留在多數決基準線的反相關通道 (1.000 對 0.762)，並在對自我一致性零配對損失的前提下突破異質性基準線 (0.923 對 0.785)。但相對於 dev 上選取的帶符號網格——掃描顯示它是遠比已發表協定更強的基線——優勢收窄到失真、回音與無標籤運作三處。兩次真實軌跡實驗界定了設定的邊界：通道在飽和基準上為零 ($z = -1.24$)，在競賽數學上為正 ($\bar{D} = +0.250$ 、 $z = +2.54$)；然而任何這類方法能作用的分層，在兩個領域五個基質上只佔題目的 2.5–7.5%。因此棄權是正確的預設，而死區恰好實現了它。

關鍵詞：大型語言模型、自我一致性、信心校準、無標籤估計、排名統計量

一、引言

自我一致性 (Self-Consistency, SC) [1] 透過取樣多條思維鏈並回傳多數答案，提升凍結大型語言模型的推理準確率。由於每條推理軌跡亦可附帶信心分數 (口頭表述 [2][3]、由 token 對數機率導出、或以 $P(\text{True})$ 形式引出 [4])，以信心加權投票是自然的改良方向。CISC [5] 證明此作法能以較低的取樣預算達到純 SC 的準確率，並提出題內辨別度 (Within-Question Discrimination, WQD) 指標，指出對投票真正有用的性質是辨別力，而非校準度。

然而這類改良存在一項結構性弱點，就我所知尚無已發表方法處理。現有加權方案，包括 CISC 的 softmax 權重、可靠度感知偽計數 [6] 與暖啟動門檻過濾 [7]，皆為信心的單調遞增函數；換言之，方法只能決定「上調權重的幅度」，卻無法表達「信心可能與正確性反相關」。方向性失準並非罕見情形：強化微調已知會扭曲口頭信心，分布位移也可能使原本有效的訊號反轉。本文實驗顯示，一條簡單的負相關通道 ($\kappa = -0.6$ ，見第三節) 足以將信心加權基線從近乎完美壓到多數決基準線；但同一份證據若以正確的符號解讀，其實是近乎完美的訊號。另一種防禦性作法是在校準誤差過高時以二元閘門關閉信心通道，此法雖可在符號反轉下存活，卻會把仍具辨別力的訊號一併丟棄：一條系統性偏低但排序完全正確的信心通道，會因與投票效用無關的理由而未能通過 ECE 閘門 [5][8]。

本文將問題歸結為估計單一純量，即信心通道的帶符號題內辨別度，再連同其不確定性映射為投票指數。主要貢獻如下。

C1: 帶符號且解析推導的信心加權。 TACT 以權重 $w_i = \exp(\gamma \varphi_i)$ 投票，其中 φ_i 為軌跡 i 題內信心中位秩的標準化 van der Waerden 分數；指數 γ 並非網格搜尋所得，而是由統計量推導：先計算混合 van Elteren Somers' D (等於 $2 \cdot \text{WQD} - 1$)，配上精確的 tie 校正零假設變異數與題內叢集 jackknife 標準誤，經帶顯著性下限的正部 James–Stein 收縮，最後經含混合變異數校正的 Bayes 判別連結。整個構造具有精確端點：收縮死區內的投票與純 SC 位元層級相同 (兩者共用同一段程式碼)，採用對數值特徵映射時則精確重現 CISC-power (第四節)。由於 φ 僅透過題內排名依賴信心，任何嚴格單調的信心尺度失真都不影響投票；在單調壓縮情形下，本方法超越了整個原始值權重家族所能達到的最佳結果 (1.000 對 0.963)。

C2: 帶符號通道可靠度的無標籤估計。 群眾外包文獻由多位標註者之間的共變異估計可靠度 [9][10]；單一

模型的單一信心通道並無此結構可用。本文改從一致性偽標籤（每題的去重加權多數決）估計帶符號辨別度，並證明類別條件雜訊下的衰減恆等式 $\mathbb{E}[\bar{D}_g] = (1 - 2\bar{\rho}) D$ ：只要成對加權的多數決錯誤率 $\bar{\rho}$ 低於 $1/2$ ，無標籤估計至多低估信任強度，不會判錯符號。方法另以 split-half 一致性反演保守地去衰減，並在識別性受威脅時由符號感知警報退回純 SC。實驗中，無標籤變體與使用 200 筆標籤的變體在整條耦合掃描上幾乎逐點相同，包括負通道的完整恢復（第八節）。越過 $\bar{\rho} < 1/2$ 之後會發生什麼，第九節有實測，答案不好看。

C3：不可能性結果與其結構化出路。當逐題耦合為 i.i.d. 且無可觀測協變量時，本文證明逐題無標籤自適應不可行：對題目自身一致性統計量的任何單調使用，都會塌縮為對多數決的增強；在多數決錯誤（亦即翻轉才可能獲勝）的題目上，可觀測符號有 96% 的比例與真實符號相反；且在池實質為二元時， $\{\kappa > 0, \text{少數方正確}\}$ 與 $\{\kappa < 0, \text{多數方正確}\}$ 兩種情形產生完全相同的可觀測分布。反之，若異質性由可觀測協變量索引（例如不同領域各有其校準特性），同一估計器按群組執行即可恢復各群組的帶符號耦合，並在對 SC 零配對損失的前提下逼近逐題最佳結果（第六節）。

C4：預先登記的證偽協定。四項證偽準則於實作前即已固定，其中兩項的設計目的就是推翻本方法：已發表的 dev 校準 CISC 協定（其調參溫度本身即為 SC 與 CISC 之間的內插），以及在 dev 上選取帶符號指數的網格基線。四項準則全數通過，且各項邊際如實報告：相對帶符號網格的淨優勢僅集中於三種情形，即單調失真、自信回音，以及網格基線無法執行的無標籤運作；在同質掃描的中段，本方法其實是落後的，這一點由十 seed 的自助法區間確立為系統性而非雜訊。

二、相關工作

信心加權自我一致性。SC [1] 將取樣軌跡視為獨立同分布的票。CISC [5] 以在標籤分割上調參的溫度執行 softmax 信心加權，其 WQD 指標提出的「辨別力重於校準度」論點與本文動機相同；排名校準文獻 [8] 亦獨立得到相同結論。加權變體 [11][14] 與提早停止方法 [12][13] 著眼於預算效率；可靠度感知偽計數 [6] 與暖啟動門檻過濾 [7] 可線上調整，但僅能縮放正向信任。上述方法皆無法表達（更遑論估計）負的信心與正確性關聯。基於此，本文的 dev 校準變體須誠實定位：CISC 的調參溫度已構成 dev 校準的 SC 與 CISC 內插，故 TACT-dev 的新意在於符號處理、排名不變性與免網格的解析映射，而非 dev 校準本身。

無標籤可靠度估計。由一致性推估工作者可靠度是統計學的經典問題 [9][15][16]；頻譜元學習 [10] 與近期結合多個 LLM 的研究 [17][18] 均仰賴多個預測器之間的共變異。本文的設定不同：僅有單一模型的單一通道、逐題投票結構，且一致性代理在相關錯誤下的失效是已知現象。本文的因應方式是給出量化的衰減恆等式、保守的去衰減與警報機制，而非宣稱無條件保證。

收縮與排名統計量。估計器由經典工具組成：分層排名統計量 [19]、James-Stein 正部估計器 [20]、有效樣本數修正 [21][22]，以及 normal-scores 判別分析。本文的貢獻在於組裝方式與其端點性質，而非個別工具。

先前的負面結果。我先前提出的系統 RLEV-VoI（冗餘折扣投票搭配資訊價值停止準則）曾以相同的證偽紀律評估，結果未能通過：一個簡單的去重基線在所有情境全面勝出，因此我將該系統以負面結果發表。正是在分析那次失敗的過程中，我注意到了本文所研究的信心兩難。

三、問題設定

3.1 記號

設題目 $q = 1, \dots, Q$ ，題 q 有 m_q 條取樣軌跡。軌跡 (q, i) 產生離散答案 $a_{q,i}$ 與信心 $c_{q,i} \in (0, 1)$ ；正確性 $y_{q,i} = \mathbf{1}[a_{q,i} = a_q^*]$ 於測試時不可觀測。純 SC 回傳 $\arg \max_A n_q(A)$ ，其中 $n_q(A)$ 為答案 A 的得票數。CISC-power 以固定 $\gamma > 0$ 依 $c_{q,i}^\gamma$ 加權。

3.2 信心兩難

實驗採用的合成 oracle 逐題自含潛在正確答案的叢集混合分布取樣軌跡，信心依下式生成：

$$c_{q,i} = \text{clip}\left(\frac{1}{2} + \kappa(y_{q,i} - \frac{1}{2}) + \varepsilon_{q,i}, 0.01, 0.99\right)$$

其中 $\varepsilon \sim \mathcal{N}(0, 0.1^2)$ 為雜訊， $\kappa \in [-0.6, 0.6]$ 為耦合強度。圖 1 為本方法設計之前先行量測的基線結果：無條件加權（CISC， $\gamma = 1$ ）在 $\kappa < 0$ 時崩潰；ECE 閘門僅在校準良好時開啟；以 dev 標籤執行符號校正的 AUC 閘門則幾乎吃滿整條同質掃描。這項預先量測界定了新方法能夠正當宣稱優勢的範圍，即信心尺度的單調失真、協變量異質性、小型 dev 集與無標籤運作四種情形；後續評測亦以此為準。




Figure 1: 圖 1：預先量測的問題陳述。固定 $K = 15$ 下，各基線信心策略的準確率隨真實耦合 κ 的變化。符號校正 AUC 閘門（綠線）幾乎吃滿同質掃描；新方法的剩餘空間（陰影）集中於中段，以及本圖之外的失真、異質性與無標籤情形。

四、TACT

4.1 投票家族

在題 q 內，令 $R_{q,i}$ 為 $c_{q,i}$ 的中位秩（同分取平均），並定義

$$\varphi_{q,i} = \frac{v_{q,i} - \bar{v}_q}{\sigma_q}, \quad v_{q,i} = \Phi^{-1}\left(\frac{R_{q,i}}{m_q + 1}\right)$$

其中 σ_q 為 v 在題內的實測標準差。此處不可改用閉式常數：無同分時 $m = 4$ 的值約 0.62， $m = 40$ 時約 0.95，閉式常數會使 γ 在不同預算下被悄悄重新縮放。若 $\sigma_q \leq 10^{-8}$ （信心全數同分），則令 $\varphi \equiv 0$ ，該題退回純 SC 投票。投票規則為

$$\hat{a}_q = \arg \max_A \sum_{i: a_{q,i} = A} \exp(\gamma \varphi_{q,i})$$

當 $\gamma = 0$ 時，實作直接呼叫 SC 常式本身，因此零信任端點為位元層級精確，而非僅在分布意義上相等。又因 φ 僅透過題內排名依賴 c ，信心尺度的任何嚴格單調失真皆不改變投票結果。

4.2 可靠度統計量

對正標籤數 n_q^1 、負標籤數 n_q^0 的題 q (dev 情形以 y 為標籤，無標籤情形以第五節的偽標籤代替)，由中位秩上的 Mann–Whitney 統計量可得

$$D_q = 2 \text{AUC}_q - 1, \quad \text{AUC}_q = \frac{U_q}{n_q^1 n_q^0}$$

此即 CISC 記號中的 $2 \cdot \text{WQD}_q - 1$ 。跨題混合採 van Elteren 成對計數權重 $N_q = n_q^1 n_q^0$ [19]:

$$\widehat{D} = \frac{\sum_q N_q D_q}{\sum_q N_q}$$

在題內可交換性的零假設下， U_q 的精確 tie 校正變異數為 $n_q^1 n_q^0 (m_q + 1) / 12 \cdot [1 - \sum_t (t^3 - t) / (m_q^3 - m_q)]$ ，由此得零假設標準誤 SE_0 ；題間異質性另以閉式的刪一題 jackknife 標準誤 SE_J 捕捉。實際使用的標準誤取保守值：

$$\text{SE} = \max(\text{SE}_0, \text{SE}_J, \frac{1}{2\sqrt{N}}), \quad r = \widehat{D} / \text{SE}$$

由於 D 為成對泛函， $\mathbb{E}[\widehat{D}]$ 與 m_q 無關；在 $m = 40$ 下估得的指數可直接用於 $m = 8$ 的部署情境。

4.3 調節映射

收縮。採帶顯著性下限 ν 的正部 James–Stein:

$$\tilde{D} = \text{sign}(\widehat{D}) \max(0, |\widehat{D}| - \nu^2 \text{SE}^2 / |\widehat{D}|)$$

死區為 $\{|r| \leq \nu\}$ ，取 $\nu_{\text{dev}} = 1.28$ 、 $\nu_{\text{LF}} = 2.33$ 。當 $\nu = 1$ 時，上式恰為 $\mathcal{N}(0, \tau^2)$ 先驗搭配插入式估計 $\hat{\tau}^2 = \max(0, \widehat{D}^2 - \text{SE}^2)$ 所得的經驗 Bayes 後驗均值 [20]。此映射為奇函數且連續，幅度不超過 $|\widehat{D}|$ ，對 $\widehat{D}$ 單調、對 SE 反單調。

連結。設題內 $\varphi | y \sim \mathcal{N}(\mu_y, s^2)$ ，且混合分布已標準化為單位變異數（此即 4.1 節標準化的效果），故 $s^2 = 1 / (1 + \bar{p}(1 - \bar{p})u^2)$ ，其中 $u = \sqrt{2} \Phi^{-1}(\frac{1+\tilde{D}}{2})$ ， $\bar{p}$ 為正確軌跡的基礎率。在此模型下，Bayes 最適的逐軌跡對數權重係數為

$$\gamma^* = \frac{u}{s} = u \sqrt{1 + \bar{p}(1 - \bar{p})u^2}$$

並以 γ_{max} 為上限（dev 取 4，無標籤取 2）。若省略混合變異數校正而直接取 $\gamma = u$ ，在 $D = 0.9$ 時會低估強通道的權重約五成。此處需說明常態性假設的實際地位： φ 在有限的 m 下只取有限多個值（ $m = 4$ 時僅四個），所以連結是一個工作模型而非精確描述；它的正當性來自端點性質與實測，不來自漸近論證。

4.4 TACT 的單一公式

兩處代數化簡讓整條 pipeline 收成一個式子。把 $\widehat{D}$ 從收縮式中提出來，James–Stein 就變成合併 z 統計量 $\zeta = \widehat{D} / \text{SE}$ 的純乘法增益；把 $u = \sqrt{2} z$ 代進連結函數，巢狀根號消失。TACT 即：

$$\hat{a}_q = \arg \max_A \sum_{i: a_{q,i}=A} \exp(\gamma \varphi_{q,i}), \quad \gamma = \left[z \sqrt{2 + 4\bar{p}(1 - \bar{p})z^2} \right]_{-\gamma_{\text{max}}}^{\gamma_{\text{max}}}$$

$$z = \Phi^{-1}\left(\frac{1}{2}[1 + \widehat{D}(1 - \nu^2/\zeta^2)_+]\right), \quad \zeta = \widehat{D}/\text{SE}$$

在預設 $\bar{p} = 1/2$ 下，指數恰為

$$\gamma = z\sqrt{2 + z^2}, \quad z = \Phi^{-1}(\widehat{\text{AUC}})$$

——一個 probit、一個平方根，全式沒有任何調校常數（ ν 是顯著水準、 $\gamma_{\max}$ 是截斷，兩者都在看資料前就固定）。死區現在是單一條件 $|\zeta| \leq \nu$ ，在其上 γ 恆為 0，投票位元等同 SC。此式已對現行實作在含所有邊界的隨機輸入上驗證等價（tests/test_formula.py）。

4.5 端點性質

命題 1 (SC 精確歸約)。 $\gamma = 0$ 時，投票在任何軌跡池上與純 SC 為同一函數，平手處理亦相同。在 $D = 0$ 下， $P(\gamma = 0) \rightarrow 2\Phi(\nu) - 1$ （dev 約 80%，無標籤約 98%），且 γ 在死區邊界連續，因此偽陽性僅施加一個任意小的指數。

命題 2 (CISC 精確歸約)。取特徵映射 $\varphi_{q,i}^{\log} = \log c_{q,i} - \overline{\log c_q}$ 時，權重等於 $\kappa_q c_{q,i}^\gamma$ （ $\kappa_q > 0$ 為逐題常數），故 argmax、平手情形與正規化得票份額均與 CISC-power(γ) 一致。

命題 3 (正則性)。複合映射 $g(\widehat{D}, \text{SE})$ 連續、為奇函數、對 $\widehat{D}$ 非遞減、幅度對 SE 非遞增，且 $g(D, 0^+) = \gamma^*(D)$ 。

以上命題的證明均為初等推導，並由公開程式碼中的單元測試驗證（共 102 項，其中零假設變異數以置換檢定驗證，收縮式的經驗 Bayes 恆等式與連結推導亦各有數值測試）。

五、無標籤估計

5.1 管線

估計流程分四步。第一步去重：在字面相似度通道上以門檻 0.95 做單鏈結分群，每條軌跡於多數決判定與成對加權中的權重為其所屬群大小的倒數。第二步偽標籤： $g_{q,i} = \mathbf{1}[a_{q,i} = M_q]$ ，其中 M_q 為去重加權多數。第三步 margin 開門：僅保留去重加權 margin 位居前六成的題目。第四步以 $\text{lab} = g$ 計算 4.2 節的統計量，得 $(\widehat{D}_g, \text{SE}_g, r_g)$ 。

5.2 符號一致性及其邊界

命題 4 (衰減恆等式)。令 $\bar{\rho}$ 為題目多數決錯誤的成對加權機率。若多數決錯誤事件在給定 y 下與 φ 獨立（類別條件雜訊假設），則 $\mathbb{E}[\widehat{D}_g] = (1 - 2\bar{\rho})D$ 。因此只要 $\bar{\rho} < 1/2$ ，即有 $\text{sign } \mathbb{E}[\widehat{D}_g] = \text{sign } D$ ：無標籤估計至多低估信任，不會判錯符號。

此恆等式在翻轉由信心本身造成時失效，典型情形即自信回音。此時「多數正確且 $D < 0$ 」與「多數因自信回音而錯誤且 $D > 0$ 」兩種情形的可觀測分布完全相同（可視為 [10] 中雙根歧義在單通道情形的對應），因此任何無標籤保證必然附帶條件；本文如實陳述此限制。

5.3 去衰減與警報

每題做 $R = 20$ 次隨機對半分割，計算兩半多數決的一致率 α 。在含 k 個有效錯誤選項（以逆 Simpson 指數估計）的單硬幣模型下， $\alpha = p^2 + (1 - p)^2/k$ ，反解得 $p = [1 + \sqrt{1 - (k + 1)(1 - k\alpha)}]/(k + 1)$ 。去衰減時將 $\widehat{D}_g$ 除以 $2p - 1$ 的自助法上界（95%，下限 0.2）而非點估計，故僅可能低估放大倍率。另設四項警報，任一觸發即令 $\gamma = 0$ ：重複塌縮（Kish 比中位數低於 0.5）、符號感知的 margin 去耦檢定、split-half 二次式的根歧義，以及有效題數不足。其中 margin 去耦警報必須以估計的信任方向為條件：若忽略符號、一律檢查「多數方的平均 φ 是否最高」，則所有良性的負相關通道都會誤觸發。這個缺陷是開發過程中實

際遭遇、診斷並修正的，相關行為已由公開測試固定。顯著性閘門作用於原始統計量 z （命題 4 保證其符號無偏），調節則作用於去衰減後的數值。另提供半無標籤模式：僅自約 50 筆 dev 標籤取符號並送入管線，同時僅停用代理符號警報，即可以極低的標註成本規避上述歧義。

六、異質性：不可能性與出路

6.1 i.i.d. 耦合下逐題自適應不可行

設 $\kappa_q \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 0.6^2)$ 且無可觀測協變量。

命題 5（自我增強）。對任何單調遞增的奇函數 h ，逐題規則 $\gamma_q = h(\widehat{D}_q^g)$ 在兩個分支上都增強多數決： $\widehat{D}_q^g > 0$ 時上調自信軌跡的權重，而這些軌跡與多數方一致； $\widehat{D}_q^g < 0$ 時上調不自信軌跡的權重，而這些軌跡同樣屬於多數方。實驗中，此類規則與 SC 在 97.5% 的題目上給出相同答案，其餘翻轉為淨損失（每 400 題翻對 1 題、翻錯 9 題）。

命題 6（贏家詛咒）。在 $|D_q| > 0.3$ 且多數決錯誤的題目（即翻轉才可能獲勝的題目）上，一致性統計量的符號僅 4% 與真實符號一致。

命題 7（兩世界不可辨識）。在池實質為二元的條件下，對任何觀測 (a, c) ，情形 $\{\kappa > 0, \text{少數方正確}\}$ 與 $\{\kappa < 0, \text{多數方正確}\}$ 產生相同的可觀測分布；構造上，對兩種真值計算的 D 滿足 $D^{w_1} = -D^{w_2}$ ，無標籤方法無法區分二者。此條件不可省略：一旦池內出現第三個有實質人數的答案叢集，兩個世界即可分離（測試中 KS 檢定 $p < 10^{-10}$ ）。命題的兩個方向都由測試釘住。實務上這個逃逸口多半用不上——自信回音格中 88% 的題目實質為二元。

因此逐題最佳結果（本實驗為 0.973）不可達成，合理的行為是退回全域估計。TACT 的死區恰好如此：在 i.i.d. 情境中，所有變體均回傳與 SC 位元層級相同的結果（不一致配對數為零）。

6.2 TACT-group

實務上的異質性多由可觀測協變量索引，例如領域或題型。當 κ 依群組標籤而定時，按群組執行估計器即可使每個群組落在第四、五節的作業範圍內；dev 樣本少於 30 題（無標籤情形少於 60 題）的群組退回全域估計。由命題 5 至 7 可知，此退回並非便宜行事，而是唯一站得住腳的預設。

七、實驗設定

實驗架構。叢集混合 oracle 逐題生成至多 $K_{\max} = 20$ 條快取軌跡，內容包括答案、信心與兩種相似度矩陣；所有方法重放相同的軌跡池，以配對方式比較並採精確 McNemar 檢定。投票預算 $K = 15$ ；掃描實驗每格 400 題，群組研究 600 題；dev 分割取 200 題（主要設定）與 50 題（小型 dev 設定）。

實驗情境。耦合掃描 $\kappa \in \{-0.6, \dots, +0.6\}$ ；三種嚴格單調的信心失真（向 0.5 壓縮、過度自信 sigmoid、四次冪），皆保排序而毀校準；i.i.d. 異質性（ $\kappa_q \sim \mathcal{N}(0, 0.6^2)$ ）；協變量結構異質性（三群組， κ 分別為 $+0.6/0/-0.6$ ）；以及自信回音毒化（錯誤叢集以信心 0.95 逐字重複）。

基線。SC；CISC-power（ $\gamma \in \{0.25, \dots, 4\}$ ）；CISC-devT，即已發表的 dev 校準協定（於 dev 上選取正向網格）；二元 ECE 閘門；SignGrid-dev，最強的簡單基線（於 dev 上選取帶符號指數網格）；另以帶符號固定指數的測試集最佳值作為上包絡參考。群組研究加入自我參照的逐題方法作為陰性對照，並以逐題連結最佳值為理論上限。

預先登記的證偽準則。判定規則在此明確寫出，因為這套協定本身即為本文的一項貢獻。每項證偽準則為該格 400 題上的精確配對 McNemar 檢定（單尾 $\alpha = 0.05$ ），並以 8.6 節的 seed 層自助法為第二道閘門：單格檢定顯著且跨 seed 區間不含零，證偽準則才成立。單格檢定在此樣本量下對抗強基線的檢定力不足，這正是設第二道閘門的理由；早先固定的 $\tau = 0.02$ 容差僅保留為表格中的報告便利，不再作為判定依據。F1: $\kappa = +0.6$ 時 TACT-dev 低於最佳固定 γ 的 CISC 超過 τ 。F2: 任一變體在掃描的任何位置低於 SC 超過 τ 。F3: 無標籤變體的掃描平均未能勝過 ECE 閘門。F4: CISC-devT 或 SignGrid-dev 在所有情境

(含失真、異質性與小型 dev) 都落在 TACT-dev 的 τ 之內。F4 是最需要這套規則的一項：單格上 TACT 減 SignGrid 的比較在掃描任何位置都達不到顯著（最小 $p = 0.08$ ，位於 $\kappa = +0.1$ ），是十 seed 的自助法才把中段落差判定為系統性。只報單 seed 檢定的協定會把中段誤判為平手。

表 1：耦合掃描 ($K = 15$ 準確率；每格 400 配對題；dev $n = 200$)。既有方法在整個負半軸停留在 SC 基準線。

κ	SC	ECE	devT	SignGrid	TACT-dev	TACT-LF	oracle
-0.6	.762	.762	.762	1.000	1.000	1.000	1.000
-0.4	.805	.805	.805	1.000	1.000	1.000	1.000
-0.2	.750	.750	.750	.985	.975	.975	.985
-0.1	.750	.750	.750	.915	.900	.890	.915
0.0	.745	.745	.760	.760	.745	.745	.772
+0.1	.777	.777	.932	.932	.907	.907	.932
+0.2	.760	.760	.985	.985	.978	.978	.985
+0.4	.785	.785	1.000	1.000	1.000	1.000	1.000
+0.6	.780	.780	1.000	1.000	1.000	1.000	1.000




Figure 2: 圖 2：信心使用效率上的主要結果。TACT-dev 與無標籤的 TACT-LF 全程貼近帶符號最佳值；CISC-devT 與 ECE 閘門在 $\kappa < 0$ 的整個區間停留在 SC 基準線。

八、結果

8.1 帶符號恢復：有標籤與無標籤

表 1 與圖 2 為掃描結果，可歸納為三點。其一，既有方法在 $\kappa < 0$ 從未離開基準線：CISC-devT 的網格僅含正向指數，ECE 閘門則始終未開啟（掃描中 dev ECE 介於 0.10 至 0.80，而通道在兩端的辨別力其實是完美的）。其二，無標籤變體與 200 標籤變體幾乎逐點相同；在 $\kappa = -0.6$ 處，原始一致性統計量為 $\widehat{D}_g = -0.81$ 、 $z = -17.6$ ，命題 4 的符號保證如預期成立，方法在零標籤下達到 1.000。其三， $\kappa = 0$ 時死區使 γ 精確為零，對 SC 的配對準確率差恆等於零；「不劣於」在此被「完全相同」取代。

推導出的指數實際上在哪裡起作用。撐起頭條 1.000 的四格 ($\kappa = \pm 0.4, \pm 0.6$) 都是 $\widehat{D}$ 飽和的格子：連結在七個飽和格上回傳的未截斷 γ^* 介於 -8.4 到 $+12.1$ 之間，實際進入投票的是上限 $\gamma_{\max} = 4$ 。在那裡起

作用的是符號，不是推導出的幅度。反過來，在 $\kappa = \pm 0.1, \pm 0.2$ 這四格，推導值嚴格落在上限之內 ($|\gamma|$ 介於 1.10 到 2.91)，TACT-dev 四格全數落後 dev 選取的帶符號網格 (0.900 對 0.915; 0.907 對 0.932; 0.975 對 0.985; 0.978 對 0.985)。合起來讀：相對已發表協定，優勢很大，且來自「能夠表達符號」這件事本身；相對帶符號網格，這個解析映射在這些格子上並不更會挑幅度。它勝過網格之處在別的地方，即 C4 點名的三種情形；而內插本身唯一真正付錢的地方是自信回音， $\gamma = -1.198$ 落在網格點之間，勝過網格最佳的 $\gamma = -1$ (0.615 對 0.568)。

表 2：對抗情境 ($K = 15$ 準確率)。「oracle」為原始值權重策略在測試集上的最佳結果；單調壓縮下排名不變性勝過該家族全體。

情境	SC	devT	SignGrid	TACT-dev	TACT-LF
單調壓縮	.775	.963	.963	1.000	1.000
單調過度自信	.775	1.000	1.000	1.000	1.000
單調四次幂	.775	1.000	1.000	1.000	1.000
異質 (i.i.d.)	.765	.765	.765	.765	.765
自信回音	.190	.190	.568	.615	.190†

† 警報觸發，方法拒絕離開 SC；此即命題 4 條件保證的預期行為。

8.2 原始值失效處的排名不變性

單調壓縮下 (表 2、圖 3)，所有信心值集中於 0.5 附近，任何 c^γ 形式的權重都近乎均勻，原始值策略即使取測試集最佳也僅達 0.963；TACT 的排名分數不受失真影響，兩個變體均達 1.000。自信回音情境中，dev 標籤揭露了反轉現象 (信心高者反而錯誤)，TACT-dev 以 $\gamma = -1.20$ 反制，取得全場最佳的 0.615，為 SC 基準線的 3.2 倍；無標籤情形下重複塌縮警報觸發，方法拒絕行動。由命題 7 可知，該格 88% 的題目實質為二元、命題所指出的逃逸口在其上不存在，因此無標籤方法對符號的任何判斷都不優於隨機，宣稱能夠判斷才是真正的錯誤。




Figure 3: 圖 3：對抗情境。虛線為原始值權重的測試集最佳。左側各組顯示排名不變性在壓縮下勝過整個原始值家族；最右側顯示有標籤變體反制自信回音，無標籤變體則觸發警報並拒絕行動。

8.3 異質性

表 3 與圖 4 為群組研究結果。在協變量結構情境中，逐群組 TACT 恢復了各群組的帶符號耦合（dev 為 $\{+4.0, 0.0, -4.0\}$ ，無標籤為 $\{+2.0, 0.0, -2.0\}$ ， $\kappa = 0$ 的群組正確落入死區），並突破了束縛所有全域策略的基準線：無標籤變體達 0.923，與逐題連結最佳值僅差 0.023，且在 600 題中對 SC 無任何配對損失（ $+83/-0$ ， $p = 2.1 \times 10^{-25}$ ）。i.i.d. 情境中，所有方法都以零不一致配對停留在基準線，含自我參照的陰性對照在內：它無法勝過它自己所導出的那個多數決。這個對照正是命題 5 至 7 的實證呈現，而它現形的地方是群組格——即使拿到逐群組估計器所利用的同一個協變量，它也只到 0.787，相對 0.785 的基準線是 600 題裡的兩題。

兩個 arm 在此格落在彼此的 seed 雜訊之內（單 seed 為 0.923 與 0.927，五 seed 平均各為 0.929 ± 0.015 ）。一個自然的解釋是兩者指數上限不同，但消融實驗否決了它：把上限掃過 $\{1, 2, 3, 4, 6, 8\}$ ，兩個 arm 都完全不動（散布皆為 0.0000），可見上限在這一格不承重，差異就是抽樣變異。這一條是本文自己提出的歸因被自己安排的後續檢查推翻的例子，如實保留。

表 3：異質性研究（600 配對題； $K = 15$ ）。

方法	群組結構	i.i.d.
SC（基準線）	.785	.752
TACT 全域（dev）	.785	.752
TACT-group（dev）	.927	.752
TACT-group（無標籤）	.923	.752
自我參照逐題法（陰性對照）	.787	.752
逐題連結最佳值（上限）	.947	.973




Figure 4: 圖 4：結構化與 i.i.d. 異質性的對照。左：具可觀測協變量時，逐群組 TACT（無標籤）自 0.785 基準線逼近逐題最佳值，且對 SC 零損失。右：可證明封閉的 i.i.d. 情境，所有方法停留在基準線，含陰性對照在內。

8.4 小型 dev 集與證偽結果

dev 縮減至 50 題時結論不變 ($|\kappa| = 0.6$ 仍為 1.000, -0.2 仍為 0.978): 考慮標準誤的收縮使方法平滑退化, 而非驟然失效。四項證偽準則全數通過: F1 (1.000 對 1.000)、F2 ($\kappa = 0$ 位元層級相同, 其餘位置未低於 SC 超過預先登記的 0.02 容差)、F3 (掃描平均 0.944 對 0.768)、F4 (兩個網格基線在失真與回音格分別落後 0.037 與 0.047, 且都無法在無標籤下運作)。

須說明的是配對檢定的實際狀況: 在單一 seed 上, 對 SignGrid-dev 的檢定在任何位置都不顯著 ($\kappa = -0.2$: 不一致配對 3/7, 精確 $p = 0.34$; $\kappa = +0.1$: 8/18, $p = 0.08$), 是 8.6 節的十 seed 區間才確立中段落差。相對 SignGrid-dev 的誠實邊際在同質掃描上很窄——TACT 在中段甚至落後 0.007 至 0.025, 這是收縮的預期代價——淨優勢正好集中在事前登記的三處: 失真 (+0.037)、回音 (+0.047), 以及網格無法執行的無標籤運作。

8.5 實作的驗證

本文第四至六節的每一項主張都是數學性質而非經驗趨勢, 因此公開程式碼為每一項配置可執行的測試; 測試套件共 102 項, 涵蓋 TACT 與後續工作。下表列出命題與測試的對應——若性質不再成立, 對應測試即失敗。

主張	證據
命題 1 (精確 SC)	200 個隨機池, 含平手處理完全相同; $D = 0$ 下死區觸發率 $> 70\%$
命題 2 (精確 CISC)	100 個池, 得票份額完全一致
命題 4 (衰減)	$\rho \in \{.1, .25, .4\}$, 絕對誤差 .06
命題 5-7	97.5% 與 SC 一致; 符號僅 4% 相符; 兩世界邊界雙向釘住 (二元池不可辨識; 出現有實質人數的第三叢集則可分離, $KS\ p < 10^{-10}$)
排名不變性	3 種失真 $\times$ 100 個池
估計器內部	置換零假設變異數 (3,000 次抽樣, 10% 容差)、JS-EB 恆等式精確至 10^{-12} 、連結式相對誤差 10^{-9} 、置換不變性迴歸測試
已否決方案	Kish ESS 與 SAFE-under-VoI 保證各有一項斷言其失敗的測試

其中兩項值得說明。置換不變性測試是在一次缺陷之後補上的: 當時快取鍵讓測試本身通過, 而估計量實際上具有高達 0.10 的順序依賴; 現行版本直接呼叫內部常式以繞過快取。最後一列則是反向測試, 斷言已否決方案 (Kish 有效樣本數公式, 以及「出貨預設遵守 SAFE 停止保證」的說法) 確實失敗, 以防後續修改悄悄將其復原。

8.6 一個 harness 假象, 以及跨 seed 的離散度

對合成結果有兩處修正, 都是把原本的單 seed 量測重跑之後才發現的。

平手處理在白送分給 SC。產生器在每一題都把正確答案編為代碼 0, 而 argmax 的平手偏向最小索引, 因此任何得票平手的題目, 純 SC 依構造就選對: 近乎平手的題目上 SC 拿 67.7%, 隨機平手處理只有 50.4%, 而 $K = 15$ 時有 31.8% 的題目是平手。任何把權重擾動離開整數的方法都會失去這份補貼, 所以這個假象同時抬高了基線並懲罰了本文方法。它還製造了一個假的證偽事件: $\kappa = 0$ 時 TACT-dev 十 seed 平均 0.797、SC 為 0.818, 觸發 F2; 但當時的指數其實都是 $|\gamma| \leq 0.05$ ——被動到的是那些平手處理改變了的題目, 不是被指數重新加權的題目。現在答案代碼逐題置換。假象移除後, 兩者在死區該成立的地

方精確重合： $\kappa = 0$ 兩法同為 0.745，異質 κ 兩法同為 0.765（十 seed 平均分別為 0.758 與 0.768，每個 seed 的不一致配對皆為零），死區的行為與命題 1 所述一致。本文所有合成數字都是修正後重跑的結果。

離散度。每格十個 seed、每 seed 400 配對題，對 seed 做自助法。兩端極穩定，第三位小數以內 ($|\kappa| \geq 0.4$ 為 1.000 ± 0.001)。中段相對 SignGrid-dev 的落差雖小但是真的，不是雜訊： $\kappa = -0.2$ 為 $-0.013 [-0.017, -0.009]$ 、 -0.1 為 $-0.016 [-0.024, -0.009]$ 、 $+0.1$ 為 $-0.012 [-0.018, -0.005]$ 、 $+0.2$ 為 $-0.013 [-0.019, -0.008]$ ，四者 $p < 0.001$ 。本文宣稱有優勢的地方同樣是真的：單調壓縮 $+0.032 [+0.027, +0.037]$ ，自信回音 $+0.048 [+0.037, +0.059]$ 。唯一在修正後改變符號的格子是異質 κ ，由損失變為 $+0.011 [0.000, +0.031]$ 。只報單一 seed 會同時藏住這個假象，以及「中段落差是系統性的」這個事實。

8.7 真實軌跡驗證

以 Claude Haiku 4.5 為凍結模型做真實軌跡驗證：100 題 (GSM8K [23] 與 CommonsenseQA 各 50 題)，每題 12 條獨立思維鏈與口頭信心（共 1,200 條軌跡），於 $K = 12, 40/60$ 的 dev/test 分割下評測。結果有四項發現。

(a) 校準與辨別的區分在真實資料上反轉，而 TACT 讀對了。此通道在傳統意義上校準極佳：ECE = 0.016，遠低於 0.10 的閘門，因此二元 ECE 閘門會開啟並把通道交給 CISC 使用。然而實測的題內辨別度為 $\widehat{D} = -0.219$ 、SE = 0.176 ($z = -1.24$)：沒有可用訊號，而僅有一點傾向還指向錯誤方向（數學 -0.515 、常識 -0.173 ，兩組皆為負）。這與合成情境恰成鏡像——在那裡 ECE 錯誤地關閉了一條具辨別力的通道（第三節），在真實資料上它卻錯誤地開啟了一條不具辨別力的通道。校準度在兩個方向上都無法反映投票效用，而帶符號的辨別度統計量正是區分兩者的依據。

(b) 死區觸發，且代價恰好為零。由於 $|z| < \nu$ ，TACT-dev、TACT-LF 與 TACT-group 一律回傳 $\gamma = 0$ ，在全部測試題上與 SC 位元層級相同（不一致配對 $+0/-0$ ， $p = 1$ ），所有方法同為 0.917。這證實了預先登記的零方向預測：通道沒有訊號時，方法不收取任何代價。

(c) 真正的限制是基準飽和，而非估計器。軌跡層級準確率在 GSM8K 為 0.958、CommonsenseQA 為 0.847，因此 100 題中僅有 12 題同時含有正確與錯誤軌跡——而這是題內秩統計量唯一能利用的題目。估計器並非設計上功效不足，是基準本身沒有讓模型面臨足夠的真實不確定性。要在強模型上暴露非零耦合，需要更難的題庫，而非每題更多軌跡。

(d) 口頭信心高度集中。兩個數值 (0.99 與 0.95) 占全部回報的 49%，在許多題目上觸發了 4.1 節的同分安全路徑。

(e) 棄權是一個量測，而且在這裡很脆弱。一個永遠不動手的規則會原封不動重現 (b)，所以這場實驗本身完全無法區分「安全機制有效」與「根本沒有訊號」。對同一批快取池做三次重放，能多分開一些。穩定性：重抽題目，dev 閘門在 50.4% 的重抽樣本中會開啟—— $|z| = 1.24$ 對 $\nu = 1.28$ ，這次棄權是 3% 的差距，不是對證據的判讀；無標籤閘門是 16.2%——但 (f) 會顯示這個數字只描述顯著性閘門本身。特異度：把信心在題內置換（保留真實邊際、同分結構、池組成與難度，只打斷耦合），誤開率為 18.4% 對名目 20%（無標籤 1.6% 對 2%），零假設 z 的 mean -0.002 、SD 0.954。死區的零假設行為因此是在真實基質上校準正確，而不只是在它自己推導所本的生成器上——這是本節唯一一項「機制真的在做事」的證據。代價：忽略閘門強制動手，推導出的 $\gamma = -0.40$ 會得到 0.933 ($+1/-0$)，真值 oracle 在 $\gamma = -1.25$ 達到 0.950，天花板是兩題。兩者都遠不到顯著，所以這個基質在要緊的意義上確實是零；但估計器推導出的符號正是 oracle 想要的符號，而 (b) 該讀成「在這個 n 下量不出代價」，不是「已證明棄權是對的」。

(f) 這個閘門在這裡本來能偵測到什麼。(e) 量的是特異度；敏感度需要一條已知強度的通道，所以把一條植入同一批池——真實答案、難度、重複結構全部不動，只替換信心向量，並以真實的對錯型態為條件。只植入估計器自己的位移模型什麼也證明不了（就是第九節提過的不變群陷阱），所以掃了四個生成族：高斯位移；同樣的位移換 Laplace 雜訊（破壞連結的常態性假設、保留 D ）；把最高信心位強制放到正確軌跡上的秩集中通道；以及只動變異數、有資訊但無符號的通道。每格 40 個 seed，四個結果。其一：閘門的操作特性是實現 $|\widehat{D}|$ 的函數、與生成族無關——半功率點約在 $|\widehat{D}| = 0.247$ （高斯）與 0.208（Laplace），全功率分別在 0.49 與 0.56，推導出的指數則分別自 0.83 與 0.95 起吃下全部 oracle 增益；在高斯的那兩個

門檻上，Laplace 族已達 0.975 功率與 0.98 capture——偵測是秩泛函的性質、不是生成器的性質，連結也在常態性被破壞下存活。(a) 量到的真實通道 $|\widehat{D}| = 0.219$ 正好落在半功率地板上：(e) 的擲硬幣，就是這條操作特性曲線的另一種說法。其二：只要閘門開啟，符號在任何族的任何格都沒錯過。其三：適用範圍的邊界是真的。秩集中通道在全強度下也只到 $|\widehat{D}| \leq 0.183$ ——合併的成對統計量幾乎看不見集中在單一秩位置的資訊——推導增益趨近零，而真值指數能拿 +0.039；無符號通道依構造不可見，閘門在其上正確維持名目誤開率。其四，一個缺陷：無標籤 arm 在任何格都不動手，即使通道近乎完美、題數門檻降到 1 也一樣，因為 100 題中 85 題全體一致，margin 開門的 40 分位切點等於 1.0，沒有任何題目能同時滿足「margin ≥ 1.0 」與「至少兩個相異答案」。所以 (b) 裡它的棄權是結構性的，不是對通道的判讀；在飽和基質上，分位數開門需要改用絕對切點。

適用範圍：單一模型、兩個基準、 $K = 12$ 。此結果乾淨地證實了零方向預測與校準—辨別論點，但並非 TACT 在真實軌跡上提升準確率的證據；發現 (c) 指出了該怎麼辦，8.8 節就去做了。

8.8 更難題目上的確認實驗

發現 (c) 預測：在飽和基準上量到為零的通道，換到模型真正不確定的題目上應該就量得到。預先註冊的後續實驗檢驗這個預測：MATH level-5 共 119 題 [24][25]，每題 16 條軌跡，同一個凍結模型；符號集 30 題、評估集 89 題，兩者在任何軌跡收集之前就從註冊清單切分完成；五項假設 H1–H5 事先固定。

通道是真的。評估集上 $\widehat{D} = +0.250$ 、 $SE = 0.098$ ，故 $z = +2.54$ ，H1 通過。這是真實軌跡上首次證實口頭信心攜帶正向的題內辨別度；同一量測在 GSM8K/CommonsenseQA 上是 -0.219 ($z = -1.24$)。

終點對任何方法都不可通過。實際跑出來的基質再次飽和：每軌跡準確率 0.819、SC 為 0.888、決定性分層只有 89 題中的 10 題，其中正解在池內的僅 4 題。池內 **oracle** 因此最多 +4/−0，精確單尾 $p = 0.0625$ 。H2 失敗，但它對每一種可想像的聚合方法（包含完美方法）都失敗，所以這是基質的性質，不是估計器的性質。

棄權行為如設計運作，但原因是兩個。TACT 在兩條無標籤路徑上都回傳 $\gamma = 0$ ，而這兩次失敗值得分開講。完全無標籤那條被 E4 與 E2 擋下：只有 13 題能帶著有變異的偽標籤通過 margin 開門，而門檻是 50；把開門的分位數一路放寬到 0 也只到 39——所以這條路徑在這個基質上、任何通道強度下都測不到。半無標籤那條被完全不同的東西擋下：它 30 題的符號集只到 $z = +0.83$ ，而門檻是 $|z| > 1$ ；同一個基質的評估集卻到 $z = +2.54$ 。那是符號集的檢定力不足、不是通道不存在，解法是加標籤而不是換方法。投票因此與 SC 位元等同，同為 0.888 (H3、H4 通過)。硬要動手的代價在同一張表上：best-single-confidence 這個「永遠相信通道」的平凡基線輸掉 4.5 分，落在 0.843。E4 是一個題數供給條件、不是對通道的判讀；而 (f) 顯示它有兩條路徑：在 8.7 節那批飽和池上，margin 開門的分位切點退化成 1.0、過閘集合對任何通道都是空的；這裡的切點是 0.875、集合非空，所以警報回報的是相對門檻的真實供給不足，不是崩潰。只有前者是缺陷。

表 4：確認實驗，MATH level-5 評估集 (89 題， $K = 16$)。所有方法重放同一批快取池。因為未收集推理文字，重複通道失效，故 dedup-SC 依構造與 SC 相同。

方法	準確率	相對 SC 淨值
SC / dedup-SC / CISC-linear	0.888	—
TACT-LF	0.888	+0/−0
TACT-semi-LF	0.888	+0/−0
best-single-confidence	0.843	+1/−5
池內 oracle (天花板)	0.933	+4/−0

這次實驗還帶出一個超出 TACT 的注意事項：量到的難度取決於收集協定。每次呼叫 30 題的探測測得 level-5 多數決正確率 0.40，每次呼叫 15 題的確認收集在同一難度層卻測得 0.888。只要軌跡是分批收集的，批次大小就該進實驗紀錄。

8.9 可作用的分層有多寬?

兩次實驗都因同一個理由未達終點，那就值得直接量那個理由。定義窗口為「多數決錯誤且正解在池內」的題目比例：這是任何無標籤聚合方法的天花板，窗口以外的題目它什麼都改不了。

窗口在跨兩個領域的五個基質上量測（表 5）。程式碼生成這一側有可執行測試提供逐樣本真值，照理窗口該更寬：40 題 LeetCode Medium/Hard [26] 各解 8 次，對基準自身的隱藏測試套件評分，基線取探測輸入上的最大行為叢集（只用輸入，不用期望輸出）。窗口是 $3/40 = 7.5\%$ (CI_{95} 2.6–19.9%)——比無標籤 QA 寬，但同一個數量級，形態也相同：30 題飽和、7 題能力牆、3 題可救援，即 75/17.5/7.5%。加預算打不開它：7 個能力牆題目在 224 次追加嘗試中零個正確（每題通過率 95% 上界 0.088），外推 $\text{oracle}@N$ 顯示窗口在 $N = 32$ 就飽和。

表 5：跨基質的可作用分層，全表採同一組定義：決定性 (Dec.) 為多數決錯誤的題目比例，窗口 (Win.) 為既決定性、正解又在池內的比例，兩者皆為百分比。窗口是任何無標籤聚合方法的天花板。† 為本文量測；HumanEval+ / MBPP+ 由已發表的 oracle 減選擇器表格重算，該來源只報窗口。題目變難時決定性比例上升，窗口卻沒有：它們從飽和直接進入能力受限。MATH L5 這一系列的分母是整份註冊清單 119 題（被量測的對象是基質本身）；8.8 節引用的則是切出符號集之後剩下的 89 題評估集上的同一組量（10 題與 4 題，即 11.2 與 4.5）。最後一列是同一個 MATH L5 基質在 8.10 節預算操作下的結果，不是第六個基質；全文引用的 2.5–7.5% 區間是上面那五列的範圍。

領域	基質	決定性	窗口
QA	GSM8K / CSQA†	9.0	4.0
QA	MATH L5†	7.6	2.5
QA	AIME / AMC†	23.3	3.3
程式碼	HumanEval+ / MBPP+	—	3.6
程式碼	LeetCode Med/Hard†	25.0	7.5
QA, 預算受限	MATH L5†	18.5	11.8

這些數字附帶一個必要的前置檢查，少了它結論會整個反過來。評分 harness 在任何候選被評分之前，先對基準自身的參考解驗證：180 題中 178 題在沙箱的資源限制下通過。這不是形式：一個資源限制被主機直接拒絕的沙箱會讓 100% 的執行失敗，而這種狀況呈現出來的樣子是「候選解不通過」，不是錯誤。用執行評分的研究都該報告自己的參考解通過率，理由和報告校準曲線一樣：沒有它，壞掉的 harness 和能力牆長得一模一樣。

8.10 第三軸：推理預算

降低每樣本準確率的辦法不只是把題目變難。限制推理預算同樣能降低它，而且正解仍留在模型的能力範圍內——這正是決定性分層需要、而難度給不了的組合：題目變難時，它們從飽和直接跨進能力受限，中間不停留。一組配對實驗在同樣的 119 題、同一個模型、同一個 K 上檢驗這件事，差別只在指示模型不要寫任何計算過程直接作答。

這個操作在它自己宣告的檢查上比預先登記的要弱（每樣本準確率 $0.853 \rightarrow 0.781$ ，未達要求的 0.10 降幅），而且正解沒有離開池 ($0.950 \rightarrow 0.933$)，所以以下屬於探索性結果。之所以要報，是因為這個限制並非均勻地拉低準確率，而是把題目搬過了多數決邊界：SC 從 0.924 掉到 0.815，窗口從 2.5% 撐開到 11.8%（對窗口成員資格做配對精確 McNemar, 13 進 2 出, $p = 0.0037$ ），而且通道變強了， $\widehat{D}$ 從 +0.229 ($z = 2.69$) 升到 +0.398 ($z = 6.76$)。被迫不寫過程直接答時，模型的信心確實跟著「這題我剛好對不對」在走。

這是全文量到最寬的窗口，也是唯一一個池內 oracle 真的越過終點的基質（+9/−0，決定性分層 17 題上 $p = 0.002$ ）。即便如此 TACT 仍回傳 $\gamma = 0$ ：通過 margin 閘門的只有 12 題，低於 30 題的門檻，E4 觸發——這是同一個題數供給條件，分位切點為 0.875、過閘集合同樣非空，並不是 (f) 所報告的那個退

化情形。這個棄權是可檢驗的，不是品味問題，而且它沒有付出代價。若改用真值標籤估計 γ ——一個任何可部署方法都拿不到的上界——最好的結果是 $\gamma = 1$ 時的 $+4/-1$ ($p = 0.19$)，而推導值 $\gamma = 0.670$ 給出 $+3/-1$ 。所以真正卡住的並不是窗口這道關。即使窗口撐到 11.8%，oracle 有能力轉換 9 題，信心加權能碰到的不到其中一半，而且沒有任何一種可達配置達到顯著。

九、討論與限制

證據涵蓋到哪裡、沒涵蓋到哪裡。本文的準確率主張全部來自合成 oracle，其信心模型在同質格上正是估計器所量測的耦合形式。有三項設計選擇用來抑制循環論證，但其中第一項比看起來弱：異質性與回音確實落在估計器的工作模型之外，然而三個失真格依構造保序，因此落在 TACT 自身的不變群之內——通過它們，測到的是實作確實尊重一個它被設計成要有的不變性，而不是探測了一個未受檢驗的區域。另外兩項成立：機制恢復 ($\hat{D}$ 是否追蹤 κ) 與準確率屬於分開報告的兩類主張；基線能力範圍 (圖 1) 在方法存在之前就量測並固定。8.7 與 8.8 節的真實軌跡實驗檢驗的是前提與棄權行為，兩項預測都成立：通道在飽和基準上為零、在競賽數學上為正，而死區在兩種情形下都讓投票與 SC 位元等同。它們不檢驗準確率主張，因為兩個基質上可作用的分層都不足以讓任何方法展示增益 (8.9 節)。

標籤充足時優勢有限。若標籤充裕且信心尺度可信，dev 上選取的帶符號網格已能取得大部分效益；TACT 的價值在於無標籤情境、失真的信心尺度、小型 dev 集，以及端點性質的精確性。

無標籤保證附帶條件，以及越界之後的後果。命題 4 要求去重後 $\bar{\rho} < 1/2$ ，且自信回音造成的歧義屬於根本限制 (命題 7)。後續工作實測了越過該邊界的後果，情況比「低估信任」嚴重得多：在改寫式錯誤多數情境中 (主導的錯誤叢集語意緊密但不含逐字特徵，去重無從著手)，多數決在多數題目上是錯的、 $\bar{\rho} > 1/2$ ，此時 TACT-LF 並非收縮向 SC，而是判錯符號、在 $\gamma = -2.0$ 觸頂，準確率歸零 (SC 地板為 0.340)。四個警報全部沒有觸發，因為 E1 依賴逐字重複，而此情境按構造不存在逐字重複。這是本方法最尖銳的未防護失效模式：保證是條件性的，該條件在無標籤下不可觀測，而現有診斷偵測不到它被違反。因此在「系統性錯誤多數」有可能出現的場合，實務上應將半無標籤模式 (以約 50 筆標籤取符號) 視為預設，而非可選的增強。另一個標準對策本文沒有試，但應該試：這個失效由一個語意緊密、而字面去重看不見的錯誤叢集驅動，而這正是語意等價分群 [27] 要塌縮的東西。把字面偽標籤換成語意偽標籤是最明顯的下一道防線，本文未予檢驗。

每群組單一指數。群組之內 TACT 僅輸出一個指數；由命題 5 至 7，群組內的逐題變異在缺乏進一步協變量時無法利用。

薄窗。8.9 節把這一類方法能作用的分層量在五個基質上都只有 2.5–7.5%，跨兩個領域，而且題目變難時不會變寬：它們從飽和直接進入能力受限。對本文的方法有兩個推論。其一，棄權不是保守的折衷而是唯一正確的預設，硬要動手的實測代價在兩個真實基質上都是負的 (表 4 中 best-single-confidence 輸 4.5 分，而死區把 TACT 精確釘在 SC 地板上)。其二，合成 harness 上那個量級的聚合增益，在這種窗口寬度下用幾百題的基準根本量不出來——這也是本文的真實資料主張只限於前提 (通道存在且帶符號) 與棄權行為，不延伸到準確率的原因。要展示增益，需要一組多數決在 30–60% 題目上出錯、而正解仍在可及範圍的 (模型、基準) 組合；本文試過的組合沒有一組同時滿足這兩個條件。至於「窗口只在外部錨便宜的地方才變寬」這個看似合理的假設，8.9 節已直接檢驗並否定：可執行真值買到的是稍寬的窗口，不是另一個 régime。而 8.10 節顯示，就算把窗口撐到 11.8%，信心加權仍碰不到 oracle 能轉換的一半——窗口之外還有第二道關。

主動把窗口撐開。這個結果也點出本文沒有做、但最值得做的方向。難度會讓題目從飽和直接跳到能力受限，但 8.10 節的預算限制是把題目搬過多數決邊界、同時把正解留在模型能力之內——這正是決定性分層需要的組合；sampling temperature 是性質相同的第二個旋鈕，兩者本文都沒有掃。如果取樣 régime 是可控輸入而非基質的固定性質，問題就從「窗口有多寬」變成「哪一組解碼設定能把最多題目放進窗口、代價是多少準確率、而且信心通道在那裡還帶不帶符號」。預算那一組實驗把第一部分回答了一次，並且顯示通道在限制下反而變強 ($\bar{D}$ 從 +0.229 到 +0.398)，但這需要在不只一個基質上確認才能相信。一個會自己選解碼預算來最大化決定性分層、然後才聚合的方法，會是與本文不同的貢獻；而這裡的量測正是它值得一試的理由。

十、結論

TACT 將「該信任模型的信心到什麼程度」轉化為可量測、帶符號、考慮不確定性的純量，並在明確陳述且經測試的條件下，於零標籤情形恢復其符號。不過框住它的那個量測比估計器本身更重要：在兩個領域五個基質上，任何無標籤聚合方法能作用的分層只有題目的 2.5–7.5%，而在兩個真實基質上，連池內 oracle 都無法通過預先登記的終點。在這種區域裡，一個估計器有用的性質是知道什麼時候不要動手，而死區正是精確地做到這件事。

程式碼與資料可得性

全部程式碼、快取軌跡，以及每張表背後的 JSON artifact，均位於 <https://github.com/vito1317/adaptive-reasoning-consensus>。8.5 節的測試表由 `pytest` 於 commit 35ad160 產生；合成結果由 `experiments/run_tact_eval.py` 產生，真實軌跡實驗由 `run_tact_hard_eval.py`，窗口量測由 `run_g1_window.py` 與 `run_g1_deepening.py`。每支腳本都會寫出其對應表格所引用的 artifact。

附錄：符號表

依首次出現順序排列。帶下標 q 的量是逐題的；除非有可用的群組協變量（第六節），估計器只輸出一個全域純量。

符號	意義
q 、 Q	題目索引；題目數
m_q 、 K	題 q 可用的軌跡數；投票預算
$a_{q,i}$ 、 a_q^*	軌跡 i 的答案；正確答案
$c_{q,i}$	自我回報的信心，落在 $(0, 1)$
$y_{q,i}$	$\mathbf{1}[a_{q,i} = a_q^*]$ ；測試時不可觀測
$\bar{p}$	正確軌跡的基礎率
$R_{q,i}$	$c_{q,i}$ 的題內中位秩（同分取平均）
$\varphi_{q,i}$	$R_{q,i}$ 的標準化 van der Waerden 分數；投票特徵
σ_q	normal scores 在題內的實測標準差
γ 、 $\gamma_{\max}$	投票指數；其上限（dev 為 4、無標籤為 2）
$\hat{a}_q$	回傳的答案
D_q	題 q 內的 Somers' D ， $= 2 \text{AUC}_q - 1 = 2 \text{WQD}_q - 1$
N_q	van Elteren 混合權重， $n_q^1 n_q^0$
$\widehat{D}$	合併後的帶符號辨別度
SE_0 、 SE_J	精確 tie 校正零假設標準誤；刪一題 jackknife 標準誤
SE	$\max\{\text{SE}_0, \text{SE}_J, 1/(2\sqrt{N})\}$
ζ	$\widehat{D}/\text{SE}$ ；死區為 $ \zeta \leq \nu$
ν	顯著性下限（dev 為 1.28、無標籤為 2.33）
$\tilde{D}$	收縮後的辨別度， $\widehat{D}(1 - \nu^2/\zeta^2)_+$
z	$\Phi^{-1}((1 + \tilde{D})/2)$
M_q	去重加權多數；即偽標籤
$g_{q,i}$	$\mathbf{1}[a_{q,i} = M_q]$
$\bar{\rho}$	多數決錯誤的成對加權機率
$\hat{\eta}$	估計的衰減量 $1 - 2\bar{\rho}$ （不是 $\bar{\rho}$ ）
α 、 k	split-half 一致率；有效錯誤選項數
$E_1 \dots E_4$	四項警報；任一觸發即令 $\gamma = 0$

符號	意義
ψ	E_2 背後的 margin 去耦統計量
κ_c	oracle 中真實的信心—正確性耦合
λ_q	i.i.d. 異質性下的逐題耦合

參考文獻

- [1] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, “Self-consistency improves chain of thought reasoning in language models,” in *Proc. ICLR*, 2023. · PDF
- [2] K. Tian *et al.*, “Just ask for calibration: Strategies for eliciting calibrated confidence scores from language models fine-tuned with human feedback,” in *Proc. EMNLP*, 2023. · PDF
- [3] M. Xiong *et al.*, “Can LLMs express their uncertainty? An empirical evaluation of confidence elicitation in LLMs,” in *Proc. ICLR*, 2024. · PDF
- [4] S. Kadavath *et al.*, “Language models (mostly) know what they know,” arXiv:2207.05221, 2022. · PDF
- [5] A. Taubenfeld *et al.*, “Confidence improves self-consistency in LLMs,” in *Findings of ACL*, 2025, arXiv:2502.06233. · PDF
- [6] J. Kim, N. Yang, K. Min, and K. Jung, “Reliability-aware adaptive self-consistency for efficient sampling in LLM reasoning,” in *Findings of ACL*, 2026, pp. 21575–21590. · PDF
- [7] Y. Fu *et al.*, “Deep think with confidence,” arXiv:2508.15260, 2025. · PDF
- [8] X. Huang, S. Li, M. Yu, M. Sesia, H. Hassani, I. Lee, O. Bastani, and E. Dobriban, “Uncertainty in language models: Assessment through rank-calibration,” in *Proc. EMNLP*, 2024, pp. 284–312. · PDF
- [9] A. P. Dawid and A. M. Skene, “Maximum likelihood estimation of observer error-rates using the EM algorithm,” *J. Roy. Statist. Soc. C*, vol. 28, no. 1, pp. 20–28, 1979. · PDF
- [10] F. Parisi, F. Strino, B. Nadler, and Y. Kluger, “Ranking and combining multiple predictors without labeled data,” *Proc. Natl. Acad. Sci.*, vol. 111, no. 4, pp. 1253–1258, 2014. · PDF
- [11] Y. Li *et al.*, “Making language models better reasoners with step-aware verifier,” in *Proc. ACL*, 2023. · PDF
- [12] P. Aggarwal, A. Madaan, Y. Yang, and Mausam, “Let’s sample step by step: Adaptive-consistency for efficient reasoning and coding with LLMs,” in *Proc. EMNLP*, 2023, pp. 12375–12396. · PDF
- [13] Y. Li *et al.*, “Escape sky-high cost: Early-stopping self-consistency for multi-step reasoning,” in *Proc. ICLR*, 2024. · PDF
- [14] Z. Kang, X. Zhao, and D. Song, “Scalable best-of-N selection for large language models via self-certainty,” in *Proc. NeurIPS*, 2025, arXiv:2502.18581. · PDF
- [15] J. Whitehill *et al.*, “Whose vote should count more: Optimal integration of labels from labelers of unknown expertise,” in *Proc. NeurIPS*, 2009. · PDF
- [16] D. R. Karger, S. Oh, and D. Shah, “Iterative learning for reliable crowdsourcing systems,” in *Proc. NeurIPS*, 2011. · PDF
- [17] J. Lee, V. Ma, S. Zhao, Y. Nair, A. Spector, R. Cohen, and E. J. Candès, “FUSE: Ensembling verifiers with zero labeled data,” arXiv:2604.18547, 2026. · PDF

- [18] R. Ai, Y. Pan, D. Simchi-Levi, M. Tambe, and H. Xu, “Beyond majority voting: LLM aggregation by leveraging higher-order information,” arXiv:2510.01499, 2025 (已獲 ICML 2026 接受) . · PDF
- [19] P. van Elteren, “On the combination of independent two-sample tests of Wilcoxon,” *Bull. Int. Statist. Inst.*, vol. 37, pp. 351–361, 1960. · PDF
- [20] W. James and C. Stein, “Estimation with quadratic loss,” in *Proc. 4th Berkeley Symp. Math. Statist. Prob.*, 1961, pp. 361–379. · PDF
- [21] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965. · PDF
- [22] J. N. K. Rao and A. J. Scott, “The analysis of categorical data from complex sample surveys,” *J. Amer. Statist. Assoc.*, vol. 76, no. 374, pp. 221–230, 1981. · PDF
- [23] K. Cobbe *et al.*, “Training verifiers to solve math word problems,” arXiv:2110.14168, 2021. · PDF
- [24] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt, “Measuring mathematical problem solving with the MATH dataset,” in *Proc. NeurIPS Datasets and Benchmarks*, 2021. · PDF
- [25] H. Lightman, V. Kosaraju, Y. Burda, H. Edwards, B. Baker, T. Lee, J. Leike, J. Schulman, I. Sutskever, and K. Cobbe, “Let’s verify step by step,” in *Proc. ICLR*, 2024. · PDF
- [26] Y. Xia, W. Shen, Y. Wang, J. K. Liu, H. Sun, S. Wu, J. Hu, and X. Xu, “LeetCodeDataset: A temporal dataset for robust evaluation and efficient training of code LLMs,” arXiv:2504.14655, 2025. · PDF
- [27] L. Kuhn, Y. Gal, and S. Farquhar, “Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation,” in *Proc. ICLR*, 2023. · PDF